

Načrt za 4. nalogo DN3

Posodobljeno po pregledu datoteke dn3_cracked.csv

Priporočena strategija

Nalogo obravnavamo kot izrazito neuravnoteženo večrazredno klasifikacijo. Glavna metrika naj bo macro-F1, ker ima razred Graduate samo 94 primerov (5,01 %). Testno množico ločimo na začetku in jo uporabimo samo enkrat, po končani izbiri modela.

Preverjeni profil podatkov

- Datoteka ima 1.875 vrstic, 57 napovednih spremenljivk in Target; prebere se z ločilom ;.
- Target: Dropout 1.406 (74,99 %), Enrolled 375 (20,00 %), Graduate 94 (5,01 %).
- V podatkih je 8.415 manjkajočih celic oziroma 7,74 % vseh napovednih vrednosti; manjkajoče vrednosti ima 40 od 57 napovednih stolpcev.
- Ni popolnih duplikatov niti dvojnikov z enakimi napovednimi spremenljivkami. Target nima manjkajočih ali neznanih oznak.

Glavno opozorilo

Samo 18 vrstic nima nobene manjkajoče napovedne vrednosti. Brisanje vseh nepopolnih vrstic bi odstranilo 99,04 % podatkov, zato uporabimo imputacijo znotraj pipeline. Šest identifikatorjem podobnih stolpcev ima od 89,2 % do 99,2 % enoličnih vrednosti in jih v osnovnem modelu izločimo.

Končni cilj

Dobiti pošteno oceno generalizacije, izbrati model na podlagi navzkrižnega preverjanja, razložiti odločitve in pustiti sledljiv zapis vseh eksperimentov. Dober rezultat ni samo najvišja ena številka, temveč rezultat brez uhajanja podatkov in z razumno uspešnostjo pri vsakem razredu.

1. Faza: audit in čiščenje podatkov

Začetni audit je pokazal, da je glavna nečistost obsežna in razpršena manjkajočnost, ne duplikati ali napačne oznake Target. Auditne celice vseeno vključimo v oddani zvezek, da so odločitve ponovljive in dokazljive.

Preverjanje	Ugotovitev v CSV	Odločitev
Branje CSV	1.875 x 58, ločilo ';', 57 napovednih stolpcev	uporabi <code>pd.read_csv(..., sep=';')</code>
Target	1.406 Dropout / 375 Enrolled / 94 Graduate; brez NaN	stratifikacija in macro-F1 sta obvezna
Manjkajoče	8.415 celic; 40 stolpcev; 1.857 vrstic z vsaj enim NaN	median/modus znotraj pipeline; ne briši vrstic
Razpon NaN	187-225 NaN na prizadeti stolpec (9,97-12,00 %)	pri numeričnih dodaj indikatorje manjkajočnosti
Duplikati	0 popolnih in 0 po napovednih spremenljivkah	ničesar ne odstranjuj zaradi podvajanja
Veljavnost	brez inf; števnici stolpci so celoštevilski; ključne relacije držijo	redkih kod ne označi za napake brez šifranta
Identifikatorji	več skoraj enoličnih kod (89,2-99,2 %)	osnovni model brez njih; ločena ablacijska kontrola

Posebej sumljivi stolpci

- Iz osnovnega modela izloči: Application number (99,0 % enoličnih), High school class number (99,2 %), Postal code (99,1 %), Study program code (98,8 %), Mentor code (89,2 %) in Last three digits of the ID.
- Stolpec Course obdrži kot kategorijo: ima le 17 vrednosti in predstavlja dejanski študijski program. Enako kategorično obravnavaj Application mode, kvalifikacije, poklice, državljanstvo in binarne kode.
- Podatki 1. in 2. semestra so lahko legitimno zelo napovedni, vendar moramo zapisati čas napovedi. Za zgodnjo napoved ob vpisu bi pomenili uhajanje iz prihodnosti; za napoved po 2. semestru pa ne.

Minimalna audit celica

```
df.shape; df.head(); df.info(); df['Target'].value_counts(dropna=False);
df.isna().mean().sort_values(ascending=False);
df.duplicated().sum(); df.nunique(dropna=False).sort_values();
```

2. Faza: pošten eksperimentalni protokol

Delitev in vse transformacije morajo preprečiti, da bi informacije iz validacije ali testa vplivale na učenje.

Korak	Priporočilo	Zakaj
Test	375 vrstic (20 %), stratificirano, random_state=42	281 Dropout, 75 Enrolled, 19 Graduate; test ostane nedotaknjen
Učenje	1.500 vrstic: 1.125 / 300 / 75	samo tu izvajamo CV, izbiro in uglaševanje
Izbira modela	StratifiedKFold(5, shuffle=True, random_state=42)	v vsakem validacijskem foldu je približno 15 Graduate
Primarna metrika	macro-F1	enaka pomembnost vseh treh razredov
Sekundarne metrike	balanced accuracy, F1 po razredih, confusion matrix	pokaže, kateri razred model zanemarja
Transformacije	ColumnTransformer + Pipeline	imputacija, kodiranje in skaliranje se naučijo samo na učenem foldu
Končna ocena	izbrani model enkrat na testu + 95 % bootstrap interval	ne izbiramo modela po testnem rezultatu

Predprocesiranje

- 17 vsebinsko kategoričnih stolpcev: oznaka missing ali najpogostejša vrednost, nato OneHotEncoder(handle_unknown='ignore'). Kode ne smejo biti obravnavane kot zvezne velikosti.
- Zvezni in številski stolpci: median imputacija z add_indicator=True; StandardScaler za logistično regresijo. S tem model vidi tudi vzorec manjkajočnosti, ne da bi brisali vrstice.
- Nobenega imputiranja, skaliranja, SMOTE ali izbire značilik ne izvajamo pred razdelitvijo oziroma zunaj pipeline.
- Številke prijave niso zanesljiv ključ (1.856 različnih vrednosti; 19 naključnih dvojic). Ne uporabljamo jih za GroupKFold in jih ne vključimo med napovedne spremenljivke.

Dve časovni različi

Če formulacija ne določa časa napovedi, je smiselno poročati: (A) polni model z vsemi legitimnimi informacijami do konca 2. semestra in (B) zgodnji model samo s podatki, znanimi ob vpisu. To ni obvezno za optimizacijo ocene, je pa močna vsebinska kontrola.

3. Faza: modeli in neuravnoteženost

Modeli naj se primerjajo po istem razrezu in istih foldih. Ker ima Graduate samo 94 primerov, začnemo z razločljivim modelom in razrednimi utežmi, nato preverimo, ali nelinearni modeli res prinesejo stabilno izboljšanje.

Poskus	Vloga	Ključne nastavitve
DummyClassifier	spodnja meja	most_frequent in stratified
Logistična regresija	razločljiv baseline	multinomial, class_weight=None/balanced, C
Random Forest / Extra Trees	nelinearnosti in interakcije	n_estimators, max_depth, min_samples_leaf, class_weight
HistGradientBoosting	močan sklearn model	learning_rate, max_leaf_nodes, min_samples_leaf; primerno kodiranje
CatBoost - opcijsko	naravno delo s kategorijami	samo če je dodatna knjižnica dovoljena; brez ID-stolpcev

Orientacijski preizkus (ni končna ocena)

Hiter 5-kratni CV na celotnem CSV, brez šestih ID-stolpcev, je dal približen macro-F1: logistična regresija 0,520; logistična regresija z utežmi 0,527; uravnoteženi Extra Trees 0,497; uravnoteženi HistGradientBoosting 0,500. To utemeljuje vrstni red poskusov, ne pa izbire končnega modela; končni protokol se izvede samo na 80 % učnem delu.

Obraznava neuravnoteženosti

- Vedno pokažemo dejanske deleže 74,99 % / 20,00 % / 5,01 %. Accuracy okoli 75 % lahko doseže že model, ki vedno napove Dropout, zato sama po sebi ni uporabna glavna mera.
- Najprej primerjamo brez popravka in class_weight='balanced'. SMOTENC dodamo kot ločen eksperiment, ne avtomatsko.
- Navadni SMOTE po one-hot kodiranju lahko ustvari nesmiselne delne kategorije. Pri mešanih podatkih je primernejši SMOTENC v imblearn Pipeline, ali pa ostanemo pri razrednih utežeh.
- Končna izbira je tista z najboljšim povprečnim macro-F1 in sprejemljivim raztrosom med foldi, ne nujno tista z najvišjo accuracy.

Iskanje parametrov

Za največ dva najboljša modela uporabimo RandomizedSearchCV z 20-40 kombinacijami in scoring='f1_macro'. Poleg povprečja beležimo standardni odklon ter posebej F1/recall za Graduate. Če sta rezultata zelo blizu, izberemo preprostejši in stabilnejši model.

Pasti

- Ne uglašujemo hiperparametrov na testni množici.
- Ne primerjamo accuracy modela z macro-F1 drugega modela.
- Ne obdržimo identifikatorja samo zato, ker izboljša CV; izboljšanje je lahko posledica naključne ali skupinske povezave.
- Feature importance ni dokaz vzročnosti. Permutacijsko pomembnost izračunamo na validacijskih/testnih podatkih in jo razlagamo previdno.

4. Faza: poročanje in sled poskusov

Ker naloga zahteva tudi neuspele poskuse, naj ima vsak poskus eno vrstico v preglednici. S tem se izognemo selektivnemu poročanju.

ID	Model / podatki	Uravnoteženje	CV macro-F1	Odločitev / opomba
E00	Dummy	brez	...	spodnja meja
E01	LogReg, brez ID	brez	... +/- ...	baseline
E02	LogReg, brez ID	class_weight	... +/- ...	vpliv uteži
E03	ExtraTrees	class_weight	... +/- ...	interakcije
E04	najboljši model + ID	enako	... +/- ...	ablacija uhajanja

Priporočena struktura rešitve v zvezku

- 4.0 Cilj, čas napovedi in izbrana metrika.
- 4.1 Nalaganje podatkov in audit z grafi razredov ter manjkajočih vrednosti.
- 4.2 Pravila čiščenja in seznam izločenih/sumljivih stolpcev.
- 4.3 Stratificirana delitev in definicija predprocesirnih pipelineov.
- 4.4 Baseline modeli.
- 4.5 Poskusi neuravnoteženosti in močnejši modeli.
- 4.6 Uglasovanje finalistov in primerjava CV.
- 4.7 Enkratna testna ocena: classification report, confusion matrix, macro-F1 in interval zaupanja.
- 4.8 Interpretacija, neuspešni poskusi, omejitve in sklep.

Grafi, ki jih je vredno vključiti

Porazdelitev Target; delež manjkajočih vrednosti; CV primerjava modelov z raztrosom; normalizirana matrika zamenjav; F1 po razredih; top permutacijske pomembnosti. Grafov naj ne bo več, kot jih lahko vsebinsko razložimo.

Kriterij za zaključek

Naloga je pripravljena za oddajo, ko se zvezek izvede od začetka do konca brez ročnih posegov, so semena fiksirana, test je uporabljen samo enkrat, poročilo vsebuje vse poskuse in so sklepi skladni s prikazanimi rezultati.

5. Predlagani potek sodelovanja s Codexom

Delo razdeliva na majhne, pregledljive korake. Po vsakem koraku preveri diff in rezultate celic, nato naredi Git checkpoint.

Krog	Kaj naročiš Codexu	Kaj ročno preveriš
1	Dodaj audit celice in preveri pričakovane številke iz tega načrta.	shape 1.875 x 58, razredi, 8.415 NaN, 0 duplikatov
2	Definiraj 17 kategoričnih, numerične in šest izločenih ID-stolpcev.	da Course ostane kategorija in ID-ji niso v X
3	Sestavi ColumnTransformer ter 80/20 stratificiran protokol.	da se imputacija in skaliranje uči le v foldu
4	Dodaj Dummy in logistični baseline ter tabelo rezultatov.	macro-F1 po foldih in po razredih
5	Primerjaj ansamble in class weights/SMOTENC.	da je resampling znotraj folda
6	Uglašuj samo dva najboljša kandidata in oceni finalista na testu.	da test ni vplival na izbiro
7	Preglej celoten zvezek, poišči leakage in napiši sklep.	ponovni Run All in ujemanje besedila z rezultati

Prvi uporaben prompt

Odpri dn3.ipynb in uporabi: V 4. nalogo dodaj audit dn3_cracked.csv. Preveri shape (1875, 58), Target 1406/375/94, 8415 manjkajočih vrednosti in nič duplikatov. Prikaži porazdelitev Target in manjkajočnost. Nato pripravi seznam 17 vsebinsko kategoričnih stolpcev ter ločen seznam šestih ID-stolpcev, vendar še ne uči modelov. Ne spreminjaj prvih treh nalog.

Naslednji nujni korak

Priloženi dn3_cracked.csv postavi v isto lokalno mapo kot dn3.ipynb. Ker je repozitorij javen in podatki vsebujejo identifikatorjem podobne stolpce, datoteko dodaj v .gitignore, dokler ni potrjeno, da jo smeš objaviti. Nato začni s 1. krogom zgoraj.