

Univerza v Ljubljani

Fakulteta za matematiko in fiziko

## **Poročilo 3. domače naloge**

4. naloga: Napovedovanje izida študija

Predmet: Izbrane teme iz analize podatkov

Študent: Enej Brus

Vpisna številka: 27221041

Ljubljana, avgust 2026

# 1 Uvod

Cilj naloge je bil na podlagi podatkov o študentih sestaviti model, ki čim bolje napove enega izmed treh možnih izidov študija: študent je študij opustil (**Dropout**), ga še vedno opravlja (**Enrolled**) ali ga je zaključil (**Graduate**). Pri tem je bilo treba preveriti kakovost podatkov, smiselno izbrati mero uspešnosti, določiti postopek delitve podatkov in ustrezno obravnavati neuravnoteženost razredov. Poleg končnega modela je bilo treba zabeležiti in primerjati tudi vse ostale poskuse.

## 2 Priprava podatkov

Podatke smo prebrali iz datoteke `dn3_cracked.csv` s knjižnico `pandas`. Ker je datoteka uporabljala podpičje kot ločilo, smo pri branju nastavili `sep=";"`. Podatkovna množica je vsebovala 1.875 vrstic in 58 stolpcev, od katerih je zadnji stolpec **Target** predstavljal ciljno spremenljivko.

Najprej smo izvedli kratek pregled podatkov. Odkrili smo 8.415 manjkajočih vrednosti oziroma 7,87 % vseh napovednih celic. Manjkajoče vrednosti so se pojavile v 40 od 57 napovednih stolpcev, popolnih vrstic pa je bilo samo 18, zato brisanje nepopolnih vrstic ne bi bilo smiselno. Popolnih duplikatov, neskončnih vrednosti in neveljavnih binarnih kod nismo našli.

Razredi so bili močno neuravnoteženi: 1.406 primerov **Dropout**, 375 primerov **Enrolled** in samo 94 primerov **Graduate**. Izločili smo tudi šest identifikatorjem podobnih stolpcev, na primer številko prijave, zadnje tri številke izkaznice in različne šifre. Ti stolpci nimajo jasnega splošnega napovednega pomena, zaradi skoraj enoličnih vrednosti pa bi lahko povzročili naključne povezave ali uhajanje informacij.

Podatke smo nato stratificirano razdelili na 80 % učne in 20 % testne množice. Tako smo dobili 1.500 učnih in 375 testnih primerov, razmerja med razredi pa so ostala približno enaka. Testno množico smo do konca pustili nedotaknjeno in jo uporabili samo enkrat za končno oceno izbranega modela.

Vso pripravo podatkov smo izvajali znotraj cevovodov. Manjkajoče numerične vrednosti smo nadomestili z mediano, kategorične pa z najpogostejšo vrednostjo. Kategorične spremenljivke smo pretvorili z one-hot kodiranjem, pri logistični regresiji pa smo numerične značilke tudi standardizirali. Tak postopek preprečuje, da bi se informacije iz validacijskega ali testnega dela uporabile že pri pripravi učnih podatkov.

## 3 Metrika in uporabljeni modeli

Kot glavno metriko smo izbrali *macro-F1*. Ta najprej izračuna F1 za vsak razred posebej, nato pa vzame njihovo povprečje, zato vse tri razrede obravnava enakovredno. Navadna točnost bi bila pri naših podatkih zavajajoča, saj bi model lahko dosegel visoko vrednost že s pogostim napovedovanjem večinskega razreda **Dropout**. Dodatno smo spremljali uravnoteženo točnost ter F1 in priklic razreda **Graduate**.

Modele smo primerjali s petkratnim stratificiranim prečnim preverjanjem. Uporabili smo naslednje modele in različice:

- dva osnovna modela `DummyClassifier` (`most_frequent` in `stratified`);
- logistično regresijo brez razrednih uteži in z utežmi `balanced`;
- Extra Trees brez razrednih uteži in z utežmi;
- HistGradientBoosting brez razrednih uteži in z utežmi;
- logistično regresijo po uravnoteženju učnega dela s postopkom SMOTENC.

SMOTENC smo uporabili namesto navadnega SMOTE, ker podatki vsebujejo tako numerične kot kategorične spremenljivke. Umetne primere je ustvarjal samo znotraj učnega dela posameznega razreza, zato ni prišlo do uhajanja podatkov. Najobetavnejša modela, logistično regresijo in HistGradientBoosting, smo nato dodatno uglaševali z `RandomizedSearchCV`, pri katerem smo za vsak model preizkusili 20 kombinacij hiperparametrov.

| Začetni poskus                  | CV macro-F1 | Opomba               |
|---------------------------------|-------------|----------------------|
| Dummy – najpogostejši razred    | 0,286       | spodnja meja         |
| Dummy – stratificirano ugibanje | 0,352       | spodnja meja         |
| Logistična regresija            | 0,548       | brez uteži           |
| Logistična regresija            | 0,550       | uravnotežene uteži   |
| Extra Trees                     | 0,384       | brez uteži           |
| Extra Trees                     | 0,510       | uravnotežene uteži   |
| HistGradientBoosting            | 0,488       | brez uteži           |
| HistGradientBoosting            | 0,533       | uravnotežene uteži   |
| SMOTENC + logistična regresija  | 0,541       | umetno uravnoteženje |

Tabela 1: Rezultati začetne primerjave modelov.

## 4 Najboljši model in rezultati

Po uglaševanju sta logistična regresija in HistGradientBoosting dosegla skoraj enak povprečni CV macro-F1, približno 0,558. Za končni model smo izbrali uglašeni **HistGradientBoosting z uravnoteženimi razrednimi utežmi**, ker je bil njegov rezultat stabilnejši med razrezi: standardni odklon je znašal 0,011, pri logistični regresiji pa 0,033. Poleg tega je dosegel višjo uravnoteženo točnost (0,635) ter boljši F1 in priklic razreda **Graduate**. Izbira je bila narejena samo na učnih podatkih, brez vpogleda v testni rezultat.

Na zaklenjeni testni množici je končni model dosegel **macro-F1 0,528**, uravnoteženo točnost 0,556 in navadno točnost 0,685. Ocenjeni 95-odstotni bootstrap interval za macro-F1 je bil [0,451, 0,601]. F1 po posameznih razredih je znašal 0,803 za **Dropout**, 0,440 za **Enrolled** in 0,341 za **Graduate**. Model je pravilno prepoznal 7 od 19 testnih primerov razreda **Graduate**.

Preverili smo tudi, kako dobro bi model deloval samo s podatki, ki so znani ob vpisu. Takšna zgodnja različica je dosegla CV macro-F1 0,408, kar je precej slabše od rezultata polnega modela. Najpomembnejše značilke končnega modela so bile povezane predvsem z odobrenimi učnimi enotami v prvem in drugem semestru, poravnanimi šolninami ter starostjo ob vpisu. Zato je naš končni model namenjen napovedovanju po drugem semestru in ne zgodnjemu opozarjanju takoj ob vpisu.

## 5 Omejitve in sklep

Glavna omejitev je majhno število primerov razreda **Graduate**. V testni množici jih je samo 19, zato sta rezultat tega razreda in skupni macro-F1 precej negotova, kar se vidi tudi iz širšega bootstrap intervala. Dodatne omejitve so manjkajoče vrednosti, odsotnost uradnega šifranta nekaterih redkih kategoričnih kod, nejasen čas nastanka nekaterih spremenljivk in dejstvo, da model ni bil preverjen na podatkih druge generacije ali druge ustanove. Ugotovljene pomembnosti značilk kažejo napovedne povezave, ne pa nujno vzročnih vplivov.

Z rezultatom smo glede na zahtevnost in močno neuravnoteženost podatkov zadovoljni, saj je končni model občutno boljši od osnovnih modelov in skuša enakovredno obravnavati vse tri izide. Kljub temu rezultat ni dovolj dober za zanesljivo samostojno odločanje o posameznih študentih, predvsem zaradi slabšega prepoznavanja razreda **Graduate**. Model je zato primernejši kot dopolnilno analitično orodje, za praktično uporabo pa bi potrebovali več podatkov, zunanjo validacijo in natančneje dokumentirane spremenljivke.