

Enostavni napovedni modeli

Ljupčo Todorovski

Univerza v Ljubljani, Fakulteta za matematiko in fiziko
Institut Jožef Stefan, Odsek za tehnologije znanja (E8)

Februar 2026

Pregled predavanja

- 1 Linearna regresija
 - Učni algoritem
 - Izbira modela in posebnosti
- 2 Logistična regresija
 - Učni algoritem
 - Izbira modela
- 3 Najbližji sosedi
 - Algoritem
 - Implementacija in izbira modela

Naloga

Podatkovna množica $S \subseteq \mathbb{R}^{p+1}$

- Numerične napovedne spremenljivke $\mathbf{X} = \langle X_1, X_2, \dots, X_p \rangle$, $D_{X_i} = \mathbb{R}$
- Numerična ciljna spremenljivka Y , $D_Y = \mathbb{R}$

Linearni model

$$\hat{y} = m(\mathbf{x}) = \beta_0 + \sum_{i=1}^p \beta_i x_i$$

- $\beta = (\beta_0, \beta_1, \dots, \beta_p) \in \mathbb{R}^{p+1}$ je vektor konstantnih parametrov modela
- Izsek (začetna vrednost) β_0 in smerni koeficienti β_i , $i = 1, 2, \dots, p$

Vektorski zapis linearnega modela s skalarnim produktom

$$\hat{y} = m(\mathbf{x}) = \mathbf{x}^T \boldsymbol{\beta} = \langle \mathbf{x}, \boldsymbol{\beta} \rangle$$

Razširjen vektor vrednosti napovednih spremenljivk $\mathbf{x} = [1 \ x_1 \ x_2 \ \dots \ x_p]^T$

- Dodana dimenzija je spremenljivka X_0 z domeno $D_{X_0} = \{1\}$
- Vrednost X_0 je 1 v vseh primerih podatkovne množice

Matrični zapis modela za podatkovno množico S

$$m(X) = X\beta = [1 \mid S_{\mathbf{x}}] \beta$$

$S_{\mathbf{x}}$ je matrika vrednosti napovednih spremenljivk v S

- Kjer so v vrsticah primeri, v stolpcih pa napovedne spremenljivke iz S
- Prvi stolpec X je dodatna spremenljivka X_0
- Zato je $\hat{\mathbf{y}} = X\beta$ vektor napovedi za vse primere iz S
- Podobno bomo z $\mathbf{y}$ zapisali vektor pravih vrednosti Y v S

Kako do vrednosti parametrov β ?

Iščemo optimalne vrednosti parametrov β za podano učno množico S

$$\min_{\beta} \sum_{\langle \mathbf{x}, y \rangle \in S} \left(y - \mathbf{x}^T \beta \right)^2 = \min_{\beta} (\mathbf{y} - X\beta)^T (\mathbf{y} - X\beta)$$

- $X \in M_{|S| \times (p+1)}(\mathbb{R})$: vrstice so primeri, stolpci napoved. spremenljivke
- $\mathbf{y} \in \mathbb{R}^{|S|}$: vrednosti ciljne spremenljivke
- $\beta \in \mathbb{R}^{p+1}$: parametri linearnega modela

Poglejmo odvod ciljne funkcije $\mathcal{L}$

$$\begin{aligned}\mathcal{L}(\beta) &= (\mathbf{y} - X\beta)^T (\mathbf{y} - X\beta) \\ &= \mathbf{y}^T \mathbf{y} - \mathbf{y}^T X\beta - \beta^T X^T \mathbf{y} + \beta^T X^T X\beta \\ &= \mathbf{y}^T \mathbf{y} - \mathbf{y}^T X\beta - (\mathbf{y}^T X\beta)^T + \beta^T X^T X\beta \\ \{\mathbf{y}^T X\beta \in \mathbb{R}\} &= \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T X\beta + \beta^T X^T X\beta\end{aligned}$$

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial \beta} &= -2(\mathbf{y}^T X)^T + 2(X^T X)\beta \\ &= -2X^T \mathbf{y} + 2X^T X\beta\end{aligned}$$

Odvod funkcije $\mathcal{L}$ po vektorju β je vektor odvodov $\mathcal{L}$ po komponentah β .

Pojasnilo glede odvajanja po vektorju

Funkcijo $\mathcal{L}: \mathbb{R}^{p+1} \rightarrow \mathbb{R}$

Odvajamo po vektorju $\beta \in \mathbb{R}^{p+1}$

Odvod $\frac{\partial \mathcal{L}}{\partial \beta}$ je

$$\left[\frac{\partial \mathcal{L}}{\partial \beta_0} \quad \frac{\partial \mathcal{L}}{\partial \beta_1} \quad \cdots \quad \frac{\partial \mathcal{L}}{\partial \beta_p} \right]^T$$

- Vektor odvodov $\mathcal{L}$ po komponentah vektorja β
- Več o odvajanju po vektorju v članku iz Wikipedie *Matrix calculus*

Metoda najmanjših kvadratov

Minimum ciljne funkcije $\mathcal{L}$ dosežemo pri

$$-2(X^T \mathbf{y} - X^T X \boldsymbol{\beta}) = 0$$

$$X^T X \boldsymbol{\beta} = X^T \mathbf{y}$$

$$\boldsymbol{\beta} = (X^T X)^{-1} X^T \mathbf{y}$$

Učni algoritem linearne regresije je torej formula

$$\boldsymbol{\beta} = (X^T X)^{-1} X^T \mathbf{y}$$

Geometrijska interpretacija

$$\hat{\mathbf{y}} = X \left(X^T X \right)^{-1} X^T \mathbf{y} = H \mathbf{y}$$

Projekcijska matrika $H = X \left(X^T X \right)^{-1} X^T$

Vektor napovedi $\hat{\mathbf{y}}$ je projekcija $\mathbf{y}$ na hiper-ravnino, ki jo razpenja X .

Napaka linearnega modela

Residualna standardna napaka, RSE

$$RSE = \sqrt{\frac{RSS}{|S| - p - 1}}, \quad RSS = \sum_{\langle \mathbf{x}, y \rangle \in S} (y - \mathbf{x}^T \boldsymbol{\beta})^2$$

$RSE \in [0, \infty)$, dober model: vrednost blizu 0.

Delež pojasnjene variance

$$R^2 = 1 - \frac{RSS}{TSS}, \quad TSS = \sum_{\langle \mathbf{x}, y \rangle \in S} (y - \bar{y})^2$$

$R^2 \in [0, 1]$, dober model: vrednost blizu 1.

Popolna napaka modela, RMSE

RMSE = Root Mean Squared Error

$$MSE = \frac{1}{|S|} \sum_{\langle \mathbf{x}, y \rangle \in S} \left(y - \mathbf{x}^T \boldsymbol{\beta} \right)^2$$
$$RMSE = \sqrt{MSE}$$

$MSE, RMSE \in [0, \infty)$, dober model: vrednosti blizu 0.

Diskretne napovedne spremenljivke

Diskretno spremenljivko X z domeno vrednosti $D_X = \{v_1, v_2, \dots, v_m\}$

- Spremenimo v numerične spremenljivke $V_k, k = 1, 2, \dots, m - 1$

$$V_k = \begin{cases} 1 & \text{če } X = v_k \\ 0 & \text{sicer} \end{cases}$$

- Domene **slamnatih** numeričnih spremenljivk $V_k: D_{V_k} = \{0, 1\}$

Interpretacija koeficienta β_k pred V_k

- Koeficient β_k je enak spremembi vrednosti ciljne spremenljivke Y
- Ki jo povzroči sprememba vrednosti spremenljivke V iz v_k v v_m

Potencialne težave

Soodvisnost napovednih spremenljivk

- Posledica $\text{rang}(X^T X) < p + 1$, torej ne moremo izračunati $(X^T X)^{-1}$
- Alternativni načini ocenjevanja β

Nelinearni vpliv spremenljivk X na Y

- Predpostavke o možnih interakcijah in nelinearnostih
- Podatkovni množici dodamo nove spremenljivke, npr. $X_1 X_2$ ali X_1^2
- Kljub dodanim spremenljivkam višje stopnje, model ostaja linearen glede na koeficiente β

Umetni podatkovni množici: Regresija

Numerične spremenljivke


- 10 napovednih spremenljivk $X_1, \dots, X_{10}$, $D_{X_i} = [0, 1]$
- Ciljna spremenljivka Y z domeno $D_Y = \mathbb{R}$

Znan model $Y = (-X_1 - 0.5X_2 + 0.5X_4 + X_5)^2 + \mathcal{N}(0, 0.05)$

- Vrednosti napovednih spremenljivk naključno ustvarjene
- Vrednostim Y dodan umeten Gaussov šum porazdeljen po $\mathcal{N}(0, 0.05)$
- Večina napovednih spremenljivk $X_3, X_6, X_7, X_8, X_9, X_{10}$ je odvečnih, saj ne vplivajo na vrednost ciljne spremenljivke Y

Dve podatkovni množici, **učna** in **testna**, vsaka po 100 primerov.

Linearna regresija na umetnih podatkih



Za diskretne ciljne spremenljivke:
Logistična regresija

Kaj, če je ciljna spremenljivka Y diskretna?

Predpostavimo binarno klasifikacijo, $D_Y = \{\oplus, \ominus\}$

- Linearni model m napoveduje verjetnost $P(Y = \oplus | \mathbf{X} = \mathbf{x})$
- Klasifikacijski model napove

$$\hat{y} = \begin{cases} \oplus & \text{če } P(Y = \oplus) \geq 0.5 \\ \ominus & \text{sicer} \end{cases}$$

Težava: ne moremo omejiti napoved linearne modela na interval $[0, 1]$.

Rešitev težave: Obeti namesto verjetnosti

$$obeti(Y = \oplus) = \frac{P(Y = \oplus)}{P(Y = \ominus)} = \frac{P(Y = \oplus)}{1 - P(Y = \oplus)}$$

Napovedujmo raje obeti namesto verjetnosti

- A obeti so še vedno na omejenem intervalu $[0, \infty)$
- Zato raje napovedujemo logaritem obetov $\log obeti(Y = \oplus)$
- Logaritem obetov je iz $(-\infty, \infty)$, lahko ga napove linearni model

Od napovedi z do verjetnosti

$$\log \text{obeti}(Y = \oplus) = \mathbf{x}^T \boldsymbol{\beta} = z$$



Rešitev enačbe $\text{obeti}(Y = \oplus) = e^z$

$$P(Y = \oplus) = \frac{e^z}{1 + e^z}, \quad P(Y = \ominus) = \frac{1}{1 + e^z}$$

Odločitvena ali klasifikacijska meja $P(Y = \oplus) = p(Y = \ominus) = 0.5$

- To se zgodi pri $e^z = 1$, t.j., pri $z = \mathbf{x}^T \boldsymbol{\beta} = 0$
- Odločitvena meja je torej (hiper-)ravnina, torej linearna

Obeti in logaritem obetov



Kako do vrednosti koeficientov?

Metoda največjega verjetja, *maximum likelihood* $\mathcal{L}$

$$\begin{aligned}\mathcal{L}(\mathbf{X}, Y; \beta) &= \prod_{\langle \mathbf{x}, y \rangle \in S} P(Y = y | \mathbf{X} = \mathbf{x}; \beta) \\ &= \prod_{\langle \mathbf{x}, y \rangle \in S: y=1} \frac{e^{\mathbf{x}^T \beta}}{1 + e^{\mathbf{x}^T \beta}} \prod_{\langle \mathbf{x}, y \rangle \in S: y=0} \frac{1}{1 + e^{\mathbf{x}^T \beta}}\end{aligned}$$

Logaritem verjetja

$$\begin{aligned}
 \log \mathcal{L} &= \sum_{\langle \mathbf{x}, y \rangle \in S: y=1} \left(\mathbf{x}^T \boldsymbol{\beta} - \log \left(1 + e^{\mathbf{x}^T \boldsymbol{\beta}} \right) \right) \Bigg| \cdot y \\
 &+ \sum_{\langle \mathbf{x}, y \rangle \in S: y=0} -\log \left(1 + e^{\mathbf{x}^T \boldsymbol{\beta}} \right) \Bigg| \cdot (1 - y) \\
 &= \sum_{\langle \mathbf{x}, y \rangle \in S} \left(\mathbf{x}^T \boldsymbol{\beta} y - \log \left(1 + e^{\mathbf{x}^T \boldsymbol{\beta}} \right) \right)
 \end{aligned}$$

Rešitev za $\boldsymbol{\beta}$: $\max_{\boldsymbol{\beta}} \sum_{\langle \mathbf{x}, y \rangle \in S} \left(\mathbf{x}^T \boldsymbol{\beta} y - \log \left(1 + e^{\mathbf{x}^T \boldsymbol{\beta}} \right) \right).$

Klasifikacijska napaka modela, CE

$CE = \textit{Classification Error}$

$$CE = \frac{1}{|S|} \sum_{\langle \mathbf{x}, y \rangle \in S} \mathbb{1}(y, \hat{y})$$

$CE \in [0, 1]$, dober model: vrednost blizu 0.

Umetni podatkovni množici: Razvrščanje

Numerične spremenljivke


- 10 napovednih spremenljivk $X_1, \dots, X_{10}$, $D_{X_i} = [0, 1]$
- Ciljna spremenljivka Y_d z domeno $D_Y = \{-1, 1\}$

Znan model $Y = (-X_1 - 0.5X_2 + 0.5X_4 + X_5)^2 + \mathcal{N}(0, 0.05)$

- Vrednosti napovednih spremenljivk naključno ustvarjene
- Vrednosti Y dodan umeten Gaussov šum porazdeljen po $\mathcal{N}(0, 0.05)$
- $Y_d = -1$, če $Y < 0.12$ in $Y_d = 1$, sicer
- Večina napovednih spremenljivk $X_3, X_6, X_7, X_8, X_9, X_{10}$ je odvečnih, saj ne vplivajo na vrednost ciljne spremenljivke Y_d

Dve podatkovni množici, **učna** in **testna**, vsaka po 100 primerov.

Logistična regresija na umetnih podatkih



Metoda najbližjih sosedov

Najbližji sosedi in soseščina

Soseščina $S_0 \subseteq S$ točke $\mathbf{x}_0$

$$S_0 = \{ \langle \mathbf{x}, y \rangle \in S : \forall \langle \mathbf{x}', y \rangle \notin S_0 : d(\mathbf{x}, \mathbf{x}_0) \leq d(\mathbf{x}', \mathbf{x}_0) \}, \quad |S_0| = k$$

- Vsebuje k primerov iz S , ki so **najbližji** primeru $\mathbf{x}_0$
- Za podano **mero razdalje** med primeri d , običajno je to **Evklidska**

Napovedni model

Regresijski model, Y je numerična

$$m(\mathbf{x}_0) = \frac{1}{k} \sum_{\langle \mathbf{x}, y \rangle \in S_0} y$$

Model vrne **povprečno vrednost** ciljne spremenljivke za primere iz soseščine.

Klasifikacijski model, Y je diskretna

- Primerjamo kardinalnosti množic $S_y = \{\langle \mathbf{x}, y \rangle \in S_0\}$ za vse $y \in D_Y$
- Model vrne vrednost y^* , za katero je $|S_{y^*}|$ največja, t.j. **modus**
- Postopek imenujemo **večinsko glasovanje**, *majority vote*

Razdalja d med primeri

Razdalja med primeri $d: \mathcal{D} \times \mathcal{D} \rightarrow \mathbb{R}$, običajno metrika

- Vrednosti so nenegativne, $d(u, v) \geq 0$
- $d(u, v) = 0$ velja natanko takrat, ko je $u = v$
- Je simetrična, $d(u, v) = d(v, u)$
- Velja trikotniško pravilo, $d(u, v) \leq d(u, w) + d(w, v)$

Običajni postopek izračuna

$$d(u, v) = \left(\sum_{i=1}^p \Delta(u_i, v_i) \right)^r$$

u_i in v_i sta vrednosti napovedne spremenljivke X_i za primera u in v .

Mere razdalje Δ med vrednostmi spremenljivke X

$$\Delta: D_X \times D_X \rightarrow \mathbb{R}$$

Primeri mer za numerične spremenljivke V

- Evklidska razdalja, $\Delta(v_1, v_2) = (v_1 - v_2)^2$, $r = 1/2$, glej prosojnico 30
- Manhattanska razdalja, $\Delta(v_1, v_2) = |v_1 - v_2|$, $r = 1$

Primer mere za diskretno spremenljivko V



$$\Delta(v_1, v_2) = \mathbb{1}(v_1 \neq v_2) = \begin{cases} 1 & \text{če } v_1 \neq v_2 \\ 0 & \text{sicer} \end{cases}$$

Učinkovito iskanje najbližjih sosedov

Časovna zahtevnost iskanja najbližjih sosedov

- Neučinkovita implementacija: linearni sprehod skozi vse primere
- Časovna zahtevnost $O(p|S|)$, lahko težavno pri velikem $|S|$ (ali p)


Učinkovita rešitev z iskalnim drevesom k-d, zahtevnost $O(p \log |S|)$




Vpliv parametra k

Število sosedov k vpliva na prilagodljivost modela



- Pri $k = 1$ se model popolnoma prilagodi učni množici
- Z večanjem k se model vedno manj prilagaja: odločitvene meje spodaj



Najbližji sosedi na umetnih podatkih: Regresija




Najbližji sosedi na umetnih podatkih: Regresija, $k = 6$





Model najbližjih sosedov **zelo občutljiv** na odvečne spremenljivke.

Najbližji sosedi na umetnih podatkih: Razvrščanje



Najbližji sosedi na umetnih podatkih: Razvrščanje, $k = 10$



Implementacija v sklearn

Linearni modeli, modul `linear_model`

- Linearna regresija, razred `LinearRegression`
- Logistična regresija, razred `LogisticRegression`

Najbližji sosedi, modul `neighbors`

- Regresija, razred `KNeighborsRegressor`
- Klasifikacija, razred `KNeighborsClassifier`
- Izračun sosesčine, razred `NearestNeighbors`

Implementacija v R

Linearni modeli

- Linearna regresija, funkcija `lm`
- Logistična regresija, funkcija `glm(family = "binomial")`

Najbližji sosedi

- Paket FNN
- Funkciji `knn.reg` in `knn` za regresijo in klasifikacijo