

Obravnava besedil in vložitve, *embeddings*

Ljupčo Todorovski

Univerza v Ljubljani, Fakulteta za matematiko in fiziko
Institut Jožef Stefan, Odsek za tehnologije znanja (E8)

April 2026

Pregled predavanja

- 1 Delno strukturirani podatki
- 2 Model vreče besed, *bag of words*
- 3 Vložitve
 - Metoda word2vec
 - Metoda doc2vec
 - Sodobni pristopi







Motivacija: klasifikacija besedil



Motivacija: razpoznavanje slik



Osnovna ideja: slovar besed



Formalizacija modela

Tri komponente O , E in f

- Osnovna podatkovna množica O : delno strukturirani podatki
- Slovar E : množica osnovnih podatkovnih elementov
- Funkcija frekvence $f : E \times O \rightarrow \mathbb{N}_0$: vrne frekvenco (število) pojavitev $e \in E$ v $o \in O$

$|E|$ spremenljivk za predstavitev delno strukturiranih podatkov iz O

- Vsakemu osnovnemu elementu $e \in E$ priredimo spremenljivko X_e
- Vrednost X_e za podatek $o \in O$ je enaka $f(e, o)$ ali njeni transformaciji

Transformacije f za besedila: frekvenca termina TF

Besedila

- O je množica besedil dokumentov $d \in O$
- E je slovar besed, imenovanih terminov, *terms* $t \in E$

Frekvenca termina, *term frequency*, $TF(t, d) = tf_{t,d} = f(t, d)$

Imenujemo jo tudi naravna frekvenca besede oziroma termina.

Alternativne mere TF

- Boolova $TF_B(t, d) = I(TF(t, d) > 0)$
- Normalizirana $TF_N(t, d) = TF(t, d)/|d|$, $|d|$ je število besed v d
- Logaritmična $TF_L(t, d) = \log(1 + TF(t, d))$

Transformacije f za besedila: frekvenca v dokumentih DF

Slabost frekvenca termina TF

Pogoste so besede brez pomena (prazne besede, *stop words*), ki se pojavijo v vsakem dokumentu iz O , na primer *in*, *ali* ali *biti*. Možni rešitvi:

- Praznih besed ne damo v slovar E
- Upoštevamo frekvenco v dokumentih DF

Frekvenca v dokumentih, *document frequency* DF

$$DF(t) = |\{d \in O : TF(t, d) > 0\}|$$

Transformacije f za besedila: *TFIDF*

Obratna frekvenca v dokumentih, *inverse document frequency IDF*

$$IDF(t) = \log \frac{|O|}{DF(t)}$$

Za prazne besede t je $IDF(t) \approx 0$, saj za njih velja $DF(t) \approx |O|$.

Alternativni meri *IDF*

- Gladka $IDF_G(t) = \log(1 + |O|/DF(t))$
- Verjetnostna $IDF_P(t) = \log(|O|/DF(t) - 1)$

$$TFIDF(t, d) = TF(t, d) \cdot IDF(t)$$

Orodja za predobdelavo besedil

Lematizacija

- Pretvorba besede v njeno osnovno obliko
- Na primer: besede *je*, *sem* in *so* imajo osnovno obliko *biti*
- Lematizator je orodje, ki besedi pripiše njeno osnovno obliko
- Lematizator za slovenščino je dostopen na lemmatise.ijs.si

Krnenje, *stemming*

- Poenostavljena in hitra lematizacija, pretvorba besede v njen koren
- Na primer: besedi *delati* in *delovanje* imata skupni koren *del*
- Krnilnik: orodje, ki besedi pripiše njen koren

Primer obdelave besedil: pet stavkov in lematizacija

Osnovni stavki

- Hotel je večji gostinski obrat, v katerem se dobi prenočišče in hrana.
- Motel je gostinski obrat hotelskega tipa, navadno ob velikih cestah zunaj naselij.
- Bi izbrali hotel ali motel?
- Janez je izbral hotel.
- Metka je najela sobo 215 v motelu v Mednem.

Lematizirani in pred-obdelani stavki

- hotel biti velik gostinski obrat v kateri se dobiti prenočišče in hrana
- motel biti gostinski obrat hotelski tip navadno ob velik cesta zunaj naselje
- biti izbrati hotel ali motel
- janez biti izbrati hotel
- metka biti najeti soba 215 v motel v Medno

Primer obdelave besedil: izračun TF_B in IDF

$$E = \{biti, hotel, motel, obrat, hrana\}$$

ID	biti	hotel	hrana	motel	obrat
1	1	1	1	0	1
2	1	0	0	1	1
3	1	1	0	1	0
4	1	1	0	0	0
5	1	0	0	1	0
DF	5	3	1	3	2
$IDF = \log(5/DF)$	0	0.7370	2.3219	0.7370	1.3219

Primer obdelave besedil: izračun *TFIDF*

ID	biti	hotel	hrana	motel	obrat
1	0	0.7370	2.3219	0	1.3219
2	0	0	0	0.7370	1.3219
3	0	0.7370	0	0.7370	0
4	0	0.7370	0	0	0
5	0	0	0	0.7370	0

Kako pridemo do slovarja E ?

Za besedila

- Običajno vse besede v dokumentih iz O
- Včasih tudi izbrane besede in njih kombinacije, n -grami
- Osnovne (korenske) oblike za lematizirana (krnjena) besedila

Za slike

- Vizualni slovar: koščki slik, ki jih lahko najdemo v slikah iz O
- Lahko ga dobimo avtomatsko z iskanjem pogostih vzorcev v slikah

Kako implementiramo f ?

Za besedila

Preprosto primerjanje besed.

Za slike

Konvolucija: konvolucijske ravni nevronske mreže pravzaprav avtomatsko odkrivajo vizualni slovar.

Omejitve

Pomen besed popolnoma nepomemben

Podobne besede iz slovarja so predstavljene z različnimi spremenljivkami.
Rešitev: vložitve, drugi del današnjega predavanja.

Veliko število spremenljivk

Rešitev: metode za izbiro in konstrukcijo napovednih spremenljivk.


Osnovna ideja: vložitev je preslikava

$$v: E \rightarrow \mathbb{R}^m$$

Pretvorba besed v vektorje realnih števil

Omejitev: Podobni vektorji ustrezajo **podobnim besedam**.

Osnovna ideja: porazdelitvena predpostavka



Porazdelitvena predpostavka, *distributional hypothesis*

Besede s podobnim pomenom se uporabljajo v istem kontekstu.

Kaj je kontekst?

Dva lematizirana stavka

- hotel biti velik gostinski obrat v kateri se dobiti prenočišče in hrana
- motel biti gostinski obrat hotelski tip navadno ob velik cesta zunaj naselje

Kontekst širine 2 za besedo *obrat*

- V prvem stavku: *velik, gostinski, v, kateri*
- V drugem stavku: *biti, gostinski, hotelski, tip*

Dva možna napovedna modela

- Napovedne spremenljivke: kontekst, ciljna spremenljivka: beseda
- Napovedna spremenljivka: beseda, ciljne spremenljivke: kontekst

Kodiranje *one-hot*

Uporabljamo ga za kodiranje besed v nevronskih mrežah.

Kodiranje besede e iz slovarja E


$$x_i = \begin{cases} 1 & ; \quad i = \text{index}(e, E) \\ 0 & ; \quad \text{sicer} \end{cases}$$

- Vektor x dolžine $|E|$
- $\text{index}(e, E)$ je indeks besede e v slovarju E
- Slovar E obravnavamo kot urejeno množico

Model *CBOW*, *Continuous Bag-of-Words*

Struktura nevronske mreže

- Vhodna raven kodira kontekst: $2k|E|$ nevronov, k je širina konteksta
- Skrita raven kodira vložitev: m nevronov, m je dim. vložitve
- Izhodna raven kodira opazovano besedo: $|E|$ nevronov



CBOW: vhodna in skrita raven

Vhodi za besede iz konteksta $w^{(c-k)}, \dots, w^{(c-1)}, w^{(c+1)}, \dots, w^{(c+k)}$

- Vsaki besedi iz konteksta $w^{(i)}$ ustreza skupina $|E|$ -tih nevronov $x^{(i)}$
- Vse besede so kodirane z *one-hot*

Sinapse in uteži

- Vsaka skupina vhodov $x^{(i)}$ je polno povezana s skrito ravnijo
- Uteži na sinapsah za različne skupine vhodnih nevronov so **enake**
- Matrika uteži W dimenzij $m \times |E|$

CBOW: stanja in izhodi skritih nevronov

$$\mathbf{v} = \frac{W_{x^{(c-k)}} + \dots + W_{x^{(c-1)}} + W_{x^{(c+1)}} + \dots + W_{x^{(c+k)}}}{2k}$$

- Vektor stanj skritih nevronov $\mathbf{v}$ je agregacija konteksta
- Za izhode stanj lahko uporabimo poljubno funkcijo aktivacije ϕ
- Običajna je identiteta $\phi(v) = v$
- Vložitev besede iz konteksta je ustrezeni stolpec iz matrike uteži W

CBOW: izhodna raven in funkcija izgube

Izhodna raven: koda *one-hot* y za centralno besedo $w^{(c)}$

$$\mathbf{z} = W' \mathbf{v}, \hat{y}_i = \frac{\exp(z_i)}{\sum_{j=1}^{|E|} \exp(z_j)}$$

- Skrita raven je polno povezana z izhodno ravni: $\mathbf{z} = W' \mathbf{v}$
- Matrika uteži W' je dimenzij $|E| \times m$
- Funkcija aktivacije *softmax*

Funkcija izgube je prečna entropija (angl. *cross entropy*)

$$L(y, \hat{y}) = - \sum_{j=1}^{|E|} y_j \log \hat{y}_j$$

CBOW: od funkcije izgube do ciljne funkcije

Ker imamo kodiranje *one-hot*, vsota ima le en člen

$$L(y, \hat{y}) = -y_i \log \hat{y}_i = -\log \hat{y}_i$$

i je indeks centralne besede $w^{(c)}$ v slovarju E .

Ciljna funkcija je zato enostavna


$$Err = -\log \hat{y}_i = -\log \frac{\exp(z_i)}{\sum_{j=1}^{|E|} \exp(z_j)} = -z_i + \log \sum_{j=1}^{|E|} \exp(z_j)$$

Od tukaj naprej vzvratno razširjanje napake.

Model *Skip-Gram*

Struktura nevronske mreže

- Vhodna raven kodira opazovano besedo: $|E|$ nevronov
- Skrita raven kodira vložitev: m nevronov, m je dim. vložitve
- Izhodna raven kodira kontekst: $2k|E|$ nevronov, k je širina konteksta



Skip-Gram: vhodna in skrita raven

Vhodi za centralno besedo $w^{(c)}$

Koda *one-hot* $x^{(c)}$ za centralno besedo.

Sinapse in uteži

- Vhodi $x^{(c)}$ so polno povezani s skrito ravnijo
- Matrika uteži W dimenzij $m \times |E|$

Skip-Gram: stanja in izhodi skritih nevronov

$$\mathbf{v} = W x^{(c)}$$

- Vektor stanj skritih nevronov $\mathbf{v}$ je vložitev besede $w^{(c)}$
- Za izhode stanj lahko uporabimo poljubno aktivacijsko funkcijo ϕ
- Označili bomo $v' = \phi(\mathbf{v})$

Skip-Gram: izhodna raven

Kode *one-hot* $y^{(j)}$ za besede iz konteksta $w^{(j)}$

$$\mathbf{z} = W' \mathbf{v}', \hat{y}_i^{(j)} = \frac{\exp(z_i^{(j)})}{\sum_{l=1}^{|E|} \exp(z_l^{(j)})}$$

- Skrita raven je polno povezana z izhodno ravni: $\mathbf{z} = W' \mathbf{v}'$
- Izhodna raven je sestavljena iz skupin izhodnih nevronov $y^{(j)}$ za vsako besedo iz konteksta $w^{(j)}$, $j = c - k, \dots, c - 1, c + 1, \dots, c + k$
- Matrika uteži W' je dimenzij $(2 \cdot k \cdot |E|) \times m$
- Aktivacijska funkcija *softmax* za vsako skupino izhodov

Skip-Gram: ciljna funkcija

Negativni logaritem verjetja konteksta za podano centralno besedo

$$Err = -\log P \left(w^{(c-k)}, \dots, w^{(c-1)}, w^{(c+1)}, \dots, w^{(c+k)} | w^{(c)} \right)$$

Predpostavka neodvisnosti besed iz konteksta (naïvni Bayes)

$$Err = -\log \prod_{j=-k, j \neq 0}^k P \left(w^{(c+j)} | w^{(c)} \right) = -\log \prod_{j=-k, j \neq 0}^k \hat{y}_{i^{(j)}}^{(c+j)}$$

Indeksi $i^{(j)}$ so indeksi besede iz konteksta $w^{(j)}$ v slovarju E .

Skip-Gram: ciljna funkcija, nadaljevanje

$$\begin{aligned}
 Err &= -\log \prod_{j=-k, j \neq 0}^k \hat{y}_{i(i)}^{(c+j)} \\
 &= -\log \prod_{j=-k, j \neq 0}^k \frac{\exp(z_{i(i)}^{(j)})}{\sum_{l=1}^{|E|} \exp(z_l^{(j)})} \\
 &= - \sum_{j=-k, j \neq 0}^k z_{i(i)}^{(j)} + \sum_{j=-k, j \neq 0}^k \log \sum_{l=1}^{|E|} \exp(z_l^{(j)})
 \end{aligned}$$

Od tukaj naprej vzvratno razširjanje napake.

Ohranjanje pomena besed

FRANCE	JESUS	XBOX	REDDISH	SCRATCHED	MEGABITS
AUSTRIA	GOD	AMIGA	GREENISH	NAILED	OCTETS
BELGIUM	SATI	PLAYSTATION	BLUISH	SMASHED	MB/S
GERMANY	CHRIST	MSX	PINKISH	PUNCHED	BIT/S
ITALY	SATAN	IPOD	PURPLISH	POPPED	BAUD
GREECE	KALI	SEGA	BROWNISH	CRIMPED	CARATS
SWEDEN	INDRA	PSNUMBER	GREYISH	SCRAPED	KBIT/S
NORWAY	VISHNU	HD	GRAYISH	SCREWED	MEGAHERTZ
EUROPE	ANANDA	DREAMCAST	WHITISH	SECTIONED	MEGAPIXELS
HUNGARY	PARVATI	GEFORCE	SILVERY	SLASHED	GBIT/S
SWITZERLAND	GRACE	CAPCOM	YELLOWISH	RIPPED	AMPERES

Ohranjanje razmerij analogije med besedami

Relationship	Example 1	Example 2	Example 3
France - Paris	Italy: Rome	Japan: Tokyo	Florida: Tallahassee
big - bigger	small: larger	cold: colder	quick: quicker
Miami - Florida	Baltimore: Maryland	Dallas: Texas	Kona: Hawaii
Einstein - scientist	Messi: midfielder	Mozart: violinist	Picasso: painter
Sarkozy - France	Berlusconi: Italy	Merkel: Germany	Koizumi: Japan
copper - Cu	zinc: Zn	gold: Au	uranium: plutonium
Berlusconi - Silvio	Sarkozy: Nicolas	Putin: Medvedev	Obama: Barack
Microsoft - Windows	Google: Android	IBM: Linux	Apple: iPhone
Microsoft - Ballmer	Google: Yahoo	IBM: McNealy	Apple: Jobs
Japan - sushi	Germany: bratwurst	France: tapas	USA: pizza

Praktična uporaba za besedilne podatke

- ➊ Naučimo model word2vec na čim večjem naboru besedil
- ➋ Uporabljamo ga za pretvorbo posameznih besed v vektorje
- ➌ Od vektorjev za besede do vektorja za besedilo
 - Izračunamo povprečje vektorjev za vse besede v besedilu
 - Izračunamo povprečje vektorjev za nekaj izbranih besed, npr. tistih z največjim *TFIDF*
 - Naredimo stik vektorjev za nekaj izbranih besed

Ali pa uporabimo doc2vec, različico word2vec za besedila.

Enostavna nadgradnja modela *CBOW*

Nadgradimo vhodno raven nevronov

- Kontekstu dodamo še eno vhodno spremenljivko: ID besedila
- Iz konteksta in ID-ja besedila napovedujemo centralno besedo

Skriti nevroni

Enako kot pri word2vec podajo predstavitev besedila z vektorjem realnih števil: podobna besedila so predstavljena s podobnimi vektorji.

Učenje mreže za vsako novo besedilo

Spreminjajo se le tiste uteži, ki se nanašajo na ID besedila, ne pa tiste, ki se nanašajo na kontekst.

Danes za vložitve dokumentov pogosteje uporabljamo jezikovne modele.

Vložitve dokumentov danes: jezikovni modeli

Osnovna ideja

Namesto učenja novega vektorja za vsak dokument uporabimo že naučen jezikovni model, ki besedilu priredi vektor glede na njegov pomen.

Ključna razlika glede na word2vec in doc2vec

- Vložitve so **odvisne od konteksta**: beseda ima lahko različne predstavitve v različnih stavkih
- Vložitev dokumenta dobimo iz predstavitve celotnega besedila
- Podobna besedila so predstavljena s podobnimi vektorji

Kako dobimo vložitev dokumenta?

Tipičen postopek uporabe jezikovnega modela

- 1 Veliki jezikovni model izračuna vložitve besed (delov besedila)
- 2 Iz njih izračunamo en sam vektor za celoten dokument

Običajni načini

- Povprečje vektorjev vseh besed (delov besedila)
- Povprečje vložitev več odsekov pri daljših dokumentih
- Poseben začetni simbol, katerega vložitev predstavlja celotno besedilo

Algoritmi in implementacije

Vreča besed

Razred `CountVectorizer` v modulu `sklearn.feature_extraction.text`.

`word2vec` (Mikolov in ost. 2013) in `doc2vec` (Le in Mikolov 2014)

- Pythonova knjižnica `nltk` za delo z besedili
- Pythonova knjižnica `gensim` za vložitve
- V R-ju je na voljo paket `textTinyR`