

Zmanjševanje razsežnosti podatkov: Izbira in tvorba napovednih spremenljivk

Ljupčo Todorovski

Univerza v Ljubljani, Fakulteta za matematiko in fiziko
Institut Jožef Stefan, Odsek za tehnologije znanja (E8)

Maj 2026

- 1 Zakaj krčenje razsežnosti?
- 2 Izbira napovednih spremenljivk
 - Rangiranje in relevantnost
 - Nenadzorovane mere relevantnosti
 - Nadzorovane mere relevantnosti
 - Relevantnost na osnovi modelov
 - Od relevantnosti do izbire
- 3 Tvorba novih spremenljivk
 - Zmanjševanje razsežnosti
 - Metoda glavnih komponent

Razdalja D naključne točke od središča enotske krogle

Prostornina p -razsežne krogle s polmerom r

$$V = r^p \pi^{\frac{p}{2}} / \Gamma\left(\frac{p}{2} + 1\right)$$

Pozor: le prvi člen r^p je odvisen od polmera; označimo $V(r) = \text{konst.} \cdot r^p$.

Porazdelitev naključne spremenljivke D

- $F_D(x) = P(D \leq x) = V(x)/V(1) = x^p/1^p = x^p, 0 \leq x \leq 1$
- $f_D(x) = F'_D(x) = p x^{p-1}$

Najmanjša razdalja M od središča za n naključnih točk

Funkcija gostote naključne spremenljivke M

$$\begin{aligned} f_M(x) &= n P(D \geq x)^{n-1} f_D(x) \\ &= n (1 - F_D(x))^{n-1} f_D(x) \\ &= n (1 - x^p)^{n-1} p x^{p-1} \end{aligned}$$

Z integracijo zgornje funkcije po x dobimo

$$F_M(x) = P(M \leq x) = 1 - (1 - x^p)^n$$

Izračun integrala

$$\begin{aligned}
F_M(x) &= \int_{-\infty}^x n(1-y^p)^{n-1} p y^{p-1} dy \\
&=_{x \geq 0} \int_0^x n(1-y^p)^{n-1} p y^{p-1} dy \\
&=_{z=y^p, dz=py^{p-1} dy} \int_0^{x^p} n(1-z)^{n-1} dz \\
&= -(1-z)^n \Big|_0^{x^p} \\
&= 1 - (1-x^p)^n
\end{aligned}$$

Alternativni izračun F_M (Rozman 2024)

$$\begin{aligned} F_M(x) &= P(M \leq x) \\ &= 1 - P(M > x) \\ &= 1 - P(D > x)^n \\ &= 1 - (1 - P(D \leq x))^n \\ &= 1 - (1 - x^p)^n \end{aligned}$$

Mediana x_m najmanjše razdalje M

$$F_M(x_m) = \frac{1}{2}$$

$$1 - (1 - x_m^p)^n = \frac{1}{2}$$

$$x_m = \left(1 - \frac{1}{2^{\frac{1}{n}}}\right)^{\frac{1}{p}}$$

Prekletstvo večrazsežnosti

- Mediana najmanjše razdalje v naključnem vzorcu n točk
- Hitro narašča proti 1 z naraščanjem razsežnosti p

Naloga rangiranja spremenljivk

Vhodi

- Množica napovednih spremenljivk $\mathbf{X} = \{X_1, X_2, \dots, X_p\}$
- Ciljna spremenljivka Y
- Podatkovna množica $S \subseteq D_{X_1} \times D_{X_2} \times \dots \times D_{X_p} \times D_Y$
- D_V je zaloga vrednosti spremenljivke V

Izhod

- Rangiranje π napovednih spremenljivk, $\pi : \mathbf{X} \rightarrow \{1, 2, \dots, p\}$
- $\pi(X_i) < \pi(X_j)$ natanko takrat, ko je X_i **bolj relevantna** od X_j
- Za napovedovanje vrednosti ciljne spremenljivke Y v množici S

Relevantnost napovedne spremenljivke

Funkcija relevantnosti $r_S : \mathbf{X} \rightarrow \mathbb{R}$

- Za podano spremenljivko $X_i \in \mathbf{X}$
- Izračuna relevantnost spremenljivke X_i za napoved vrednosti Y
- V podatkovni množici S

Ključno vprašanje: kako izračunamo vrednost r_S ?

Ko izračunamo relevantnost, postane problem rangiranja trivialno rešljiv.

Taksonomija mer relevantnosti

Relevantnost brez napovednega modela

- Nenadzorovane, izračunane iz $S_X = \{\mathbf{x} : (\mathbf{x}, y) \in S\}$
- Nadzorovane, izračunane iz S

Relevantnost na osnovi napovednega modela $m : D_{X_1} \times \dots \times D_{X_p} \rightarrow D_Y$

- Izračun relevantnosti na osnovi m
- Torej očitno nadzorovane, izračunane iz S

Podatkovna množica *Arcene*

Napovedovanje raka na osnovi masne spektrometrije

- Napovedne spremenljivke: koncentracije proteinov določene mase
- Vrednosti ciljne spremenljivke: zdrava oseba ali pacient z rakom
- Problem dvojiške klasifikacije



Velikost podatkovne množice

- 10.000 napovednih spremenljivk (7.000 realnih, 3.000 umetnih)
- 100 učnih primerov, dodatnih 100 primerov v testni množici

Varianca numerične spremenljivke

Intuitivna razlaga


- Spremenljivke z majhno varianco nimajo napovedne moči
- Varianca je torej pozitivno povezana z relevantnostjo
- POZOR: ista merska lestvica (ali pa vsaj normalizacija)



Izbira spremenljivk na osnovi variance: *Arcene*

Izberemo q najbolj relevantnih spremenljivk, običajno $q \ll p$

- Iz tako skrčene učne množice S_q se naučimo drevo T_q
- Na testni množici izmerimo napovedno točnost drevesa T_q



Entropija diskretne spremenljivke

$$H(X_i) = - \sum_{v \in D_{X_i}} p_v \log_2 p_v, \quad p_v = \frac{|S_{X_i=v}|}{|S|}$$

Varianta variance za diskretne spremenljivke

- $S_{X_i=v}$ je podmnožica učnih primerov $e \in S$, za katere velja $X_i = v$
- Po analogiji z varianco: višja entropija ustreza večji relevantnosti

Univariatne metode

Osredotočenost na povezavo med X_i in Y

- Ker uporabljajo podatke o Y , jim rečemo nadzorovane
- Ker ignorirajo vrednosti $X_j : j \neq i$, so univariatne

Mere in statistični testi povezanosti

Izbira je odvisna od tipov spremenljivk X_i in Y

X_i in Y diskretni: χ^2 in vzajemna informacija

Vrednost statistike χ^2

- Kontingenčna tabela T dimenzij $|D_{X_i}| \times |D_Y|$
- T_{ij} je število primerov z določeno kombinacijo vrednosti X_i in Y
- Statistični test za merjenje povezanosti med X_i in Y


Vzajemna informacija $I(X_i; Y)$

$$I(X_i; Y) = H(X_i) + H(Y) - H(X_i, Y)$$

- $H(X_i, Y)$ je skupna entropija X_i in Y
- $H(X_i)$ in $H(Y)$ sta entropiji X_i in Y


Primeri na množici *heart*

X-squared: 20.62333



$$I(\text{gender}) = 0.0591$$

X-squared: 6.347929



$$I(\text{fbs}) = 0.0158$$

X_i in Y različnih tipov: Welchov t -test ali ANOVA



Welchov t -test

- Primerjamo povprečji numerične spremenljivke v dveh skupinah
- Vrednosti numerične spremenljivke razdelimo v dve skupini glede na vrednost diskretne spremenljivke
- Uporaben le v primeru, ko ima diskretna spremenljivka dve vrednosti

Test ANOVA

V primerih, ko ima diskretna spremenljivka več kot dve možni vrednosti.


Primeri na množici *Arcene*



Izbira spremenljivk na osnovi t -testa: *Arcene*

Izberemo q najbolj relevantnih spremenljivk, običajno $q \ll p$

- Iz tako skrčene učne množice S_q se naučimo drevo T_q
- Na testni množici izmerimo napovedno točnost drevesa T_q



X_i in Y numerični: korelacijski koeficienti

Mere linearne povezanosti med X_i in Y

Pearsonov korelacijski koeficient



$$\rho^2(X_i, Y) = \frac{(\mathbb{E}[X_i Y] - \mathbb{E}[X_i] \mathbb{E}[Y])^2}{\text{Var}[X_i] \text{Var}[Y]}$$

Alternativi Pearsonovemu korelacijskemu koeficientu

- Spearmanov
- Kendallov

Relief: ilustracija ideje

Na podlagi modela najbližjih sosedov



Relief: razlaga ideje

Za naključno izbran primer e iz S opazujemo najbližja sosed

- **Zadetek** e_H : najbližji sosed primera e , ki pripada istemu razredu
- **Zgrešek** e_M : najbližji sosed primera e , ki ne pripada istemu razredu

Dva primera

- 1 $|x_H - x| \ll |x_M - x|$ je **dober** znak za relevantnost X
- 2 $|x_H - x| \gg |x_M - x|$ je **slab** znak za relevantnost X

x , x_H in x_M so vrednosti X za primere e , e_H in e_M .

Algoritem *Relief*

Require: S je množica primerov e

Require: m je število vzorčenih primerov

Ensure: R je vektor pomembnosti spremenljivk iz S

function Relief(S, m)

$R = [0, 0, \dots, 0]$

for $i = 1$ to m **do**

Izberi naključen primer $e = (\mathbf{x}, y) \in S$

Poišči $e_H = (\mathbf{x}_H, y_H) \in S$, najbližjega sosedu e , tako da velja $y_H = y$

Poišči $e_M = (\mathbf{x}_M, y_M) \in S$, najbližjega sosedu e , tako da velja $y_M \neq y$

for $j = 1$ to p **do**

$R[j] = R[j] + (|\mathbf{x}_{Mj} - \mathbf{x}_j| - |\mathbf{x}_{Hj} - \mathbf{x}_j|)/m$

end for

end for


return R

end function

Izbira spremenljivk na osnovi *Relief*: *Arcene*

Izberemo q najbolj relevantnih spremenljivk, običajno $q \ll p$

- Iz tako skrčene učne množice S_q se naučimo drevo T_q
- Na testni množici izmerimo napovedno točnost drevesa T_q



Razumljivi modeli in relevantnost

Iz učne množice se naučimo **razumljiv** model m

Iz modela m **preberemo** relevantnosti napovednih spremenljivk.

Linearni modeli

- $r_S(X_i)$ je proporcionalna absolutni vrednosti ustrezne uteži $|w_i|$
- Lahko upoštevamo še intervale zaupanja, če smo jih izračunali

Odločitvena drevesa, možni oceni

- 1 Število vozlišč v drevesu, kjer test temelji na X_i
- 2 Povprečno zmanjšanje nečistoče (IR) v vozliščih s testom X_i

Naključni gozdovi in relevantnost: zmanjšanje točnosti

Opazujmo razliko $D = Err(M, S_{P_i}) - Err(M, S)$ med napakami modelov

- M , ki smo ga zgradili iz učne množice S_{train}
- S_{P_i} dobimo iz množice S : vrednosti spremenljivke X_i v S_{P_i} so naključna permutacija vrednosti X_i v S
- $Err(M, S_{P_i})$ je napaka modela, kjer je vpliv spremenljivke X_i izničen

Vrednost razlike D je povečanje napake (in zmanjšanje točnosti)

- Visoka, če ima X_i **visoko** napovedno moč
- Nizka, če ima X_i **nizko** napovedno moč

Zmanjšanje točnosti za poljuben model

Isti izračun za poljuben model $D = Err(M, S_{P_i}) - Err(M, S)$

- Napaka modela M na množici S
- Napaka modela M na množici S_{P_i} , kjer so vrednosti X_i naključna permutacija pravih vrednosti X_i v S

Tak trik permutacije lahko uporabimo v kombinaciji s poljubnim modelom oz. algoritmom za strojno učenje.

Metodi filtriranja

Filtriranje s pragom (spodnjo mejo) relevantnosti r_T

- Izberi le spremenljivke $X_i : r_S(X_i) \geq r_T$
- Priporočena vrednost za *Relief*: $r_T = 1/\sqrt{\alpha p}$, kjer je α verjetnost, da med relevantne izberemo irelevantno spremenljivko X_i

Filtriranje s številom spremenljivk



Izberi q najbolj relevantnih spremenljivk, običajno $q \ll p$.

Pri obeh si običajno pomagamo z rangirnim grafom

- x-os: spremenljivke, urejene po padajoči vrednosti $r_S(X_i)$
- y-os: relevantnost spremenljivk



Rangirni grafi: *Arcene*

Hitro izračunljivi




Opazovanje napovedne napake: *Arcene*


Računsko zahtevni, a bolj informativni



Primerjava mer relevantnosti: *Arcene*



Korelacije med merami relevantnosti: *Arcene*



Znani algoritmi in implementacije

Relief (Kira in Rendell 1992)

Osnovni Relief za dvojiško razvrščanje.

RRelief (Robnik-Šikonja in Kononenko 2003)

Različne nadgradnje osnovnega algoritma, tudi za regresijo.

Paket CORELearn

Implementacija algoritmov Relief in RRelief v R-ju.

Naloga zmanjševanja razsežnosti

Vhodi

- Množica spremenljivk $\mathbf{X} = \{X_1, X_2, \dots, X_p\}$
- Podatkovna množica $S \subseteq D_{X_1} \times \dots \times D_{X_p}$; D_V je zaloga vrednosti V
- Pozor: ni ciljne spremenljivke Y , nenadzorovani scenarij

Izhod

- Množica spremenljivk $\mathbf{Z} = \{Z_1, Z_2, \dots, Z_q\}$
- Transformiran prostor nižje razsežnosti, $q < p$, pogosto $q \ll p$
- Običajno linearna transformacija oblike $Z = XW$

Zmanjševanje razsežnosti in izbira spremenljivk



Izbira spremenljivk je tudi linearna transformacija oblike $Z = XW$

$$W = \begin{bmatrix} I_{q \times q} \\ 0_{(p-q) \times q} \end{bmatrix}$$

- Matrika W ima dimenzije $p \times q$
- Predpostavka: spremenljivke X so urejene po padajoči relevantnosti

Izbira spremenljivk in tvorba novih spremenljivk

- Levo: izbira spremenljivk
- Desno: tvorba novih spremenljivk



Naloga

Iščemo W za transformacijo $Z = X W$ z omejitvama


- 1 Stolpci matrike W so ortonormirani, zato velja $W^T W = I_q$
- 2 Dimenzije Z pojasnijo čim več variance izvornih podatkov

Predpostavimo

- Vse spremenljivke v X imajo povprečje 0
- Matrika razpršenosti (neskalirana kovariančna matrika) je $X^T X$

Osnovna ideja: od variance do lastnih vektorjev

- Matrika razpršenosti je
 $C = X^T X$
- Opazujemo iteracijo $\mathbf{w} \leftarrow C\mathbf{w}$
- Za poljuben začetni vektor (1)
- Iteracija usmeri vektor v smer največje variance
- Torej za smer $\mathbf{w}$ največje variance velja $C\mathbf{w} = \lambda\mathbf{w}$



Lastni vektorji in lastne vrednosti

Spomnimo se (LA): za lastni vektor $\mathbf{w}$ matrike C velja

$$C\mathbf{w} = \lambda\mathbf{w}$$

$\mathbf{w}$ je lastni vektor matrike C pri lastni vrednosti λ

Matrika razpršenosti C je simetrična, torej $C^T = C$

Izberimo dva lastna vektorja $\mathbf{u}$ in $\mathbf{v}$ pri lastnih vrednostih λ in $\mu \neq \lambda$

$$\begin{aligned}(\lambda - \mu) \langle \mathbf{u}, \mathbf{v} \rangle &= \lambda \mathbf{u}^T \mathbf{v} - \mu \mathbf{u}^T \mathbf{v} \\&= (\lambda \mathbf{u})^T \mathbf{v} - \mathbf{u}^T (\mu \mathbf{v}) = (C\mathbf{u})^T \mathbf{v} - \mathbf{u}^T (C\mathbf{v}) \\&= \mathbf{u}^T C^T \mathbf{v} - \mathbf{u}^T C \mathbf{v} = 0\end{aligned}$$

Njun skalarni produkt $\langle \mathbf{u}, \mathbf{v} \rangle = 0$, lastna vektorja sta torej ortogonalna.

Algoritem za izračun W

Za podano matriko X izračunamo matriko razpršenosti C

Če imajo vse spremenljivke v X povprečje 0, je to $X^T X$

Za C izračunamo lastne vektorje $\mathbf{w}_i$ in lastne vrednosti λ_i

$$W = [\mathbf{w}_1 \mathbf{w}_2 \cdots \mathbf{w}_p], \Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_p)$$

- Ker je C simetrična, velja $W^T W = I$ (prejšnja prosojnica)
- Velja tudi $C = W \Lambda W^T$
- Indeksi lastnih vektorjev so taki, da velja $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$

Matrika W in glavne komponente

Glavne komponente so stolpci matrike W

Torej **lastni vektorji** matrike $C = X^T X$.

λ_i pove, koliko variance pojasni komponenta w_i

Lastne vrednosti matrike C pretvorimo v deleže celotne variance.

Matrika W in zmanjševanje razsežnosti

$$Z = X W_q$$

Izberemo prvih q glavnih komponent (lastnih vektorjev)

- W_q je matrika dimenzij $p \times q$
- Vsebuje prvih q stolpcev matrike W

Kako izberemo vrednost q ?

Hevristike za izbiro q


Najprej narišemo graf *scree* (naslednja prosojnica)

Izberemo q , pri katerem je


- 1 Kumulativna pojasnjena varianca večja od podanega praga (običajno je vrednost praga 80% ali 90%)
- 2 Prispevek k pojasnjeni varianci še vedno večji od podanega praga (običajno je vrednost praga 5% ali 10%)
- 3 Prvo **vidno koleno** v krivulji *scree*

Primer grafa *scree*: *Arcene*


Po prvi hevristici je $q = 42$, po drugi in tretji pa $q = 3$



Izbira glavnih komponent: *Arcene*



Glavne komponente in vizualizacija: *Arcene*



Implementacija

Scikit-Learn

Razred `sklearn.decomposition.PCA`.

`prcomp`

V R-ju metodo glavnih komponent implementira vgrajena funkcija.