

Obravnava manjkajočih vrednosti in neenakomerne porazdelitve vrednosti ciljne spremenljivke

Ljupčo Todorovski

Univerza v Ljubljani, Fakulteta za matematiko in fiziko
Institut Jožef Stefan, Odsek za tehnologije znanja (E8)

Maj 2026

- 1 Manjkajoče vrednosti
 - Brisanje podatkov
 - Nadomeščanje manjkajočih vrednosti (*imputation*)
 - Izjema
- 2 Neenakomerne porazdelitve
 - Težava in rešitve
 - Metoda SMOTE

Brisanje primerov

Standardni prijem za obravnavo manjkajočih vrednosti ciljne spremenljivke

Analiza popolnih primerov (*Complete-Case Analysis*)

Iz podatkovne množice odstranimo vse **primere** z manjkajočimi vrednostmi katere koli spremenljivke.

Dve težavi

- V podatke in naučene modele vnesemo predsodek
- Podatkovna množica ima premalo primerov za učenje

Brisanje napovednih spremenljivk

Analiza popolnih spremenljivk (*Complete-Variable Analysis*)

Iz podatkovne množice odstranimo vse **napovedne spremenljivke** z manjkajočimi vrednostmi.

Dve težavi

- V podatke in naučene modele vnesemo predsodek
- Odstranimo tudi **pomembne** napovedne spremenljivke

Nadomeščanje s povprečjem

Manjkajoče vrednosti spremenljivke nadomestimo s povprečjem (modusom) njenih znanih vrednosti; težava je zmanjšanje variance

Povprečje **numerične** spremenljivke X v podatkovni množici S

$$m_X = \frac{1}{|\{e \in S : X_e \in D_X\}|} \sum_{e \in S : X_e \in D_X} X_e$$

Modus **diskretne** spremenljivke X v podatkovni množici S

$$m_X = \arg \max_{v \in D_X} |\{e \in S : X_e = v\}|$$

Znana vrednost spremenljivke X , ki je najbolj zastopana v množici S .

Nadomeščanje z novo vrednostjo in/ali spremenljivko

Diskretna spremenljivka X

Neznane vrednosti nadomestimo z novo vrednostjo $v \notin D_X$.

Numerična spremenljivka X

- Vpeljemo novo spremenljivko $M_X = \mathbb{1}(X = \text{NA})$
- Neznane vrednosti X nadomestimo s povprečjem (ali 0)

Naključno nadomeščanje (dejanje iz obupa)

Vsako manjkajočo vrednost spremenljivke X nadomestimo z naključno izbrano znano vrednostjo $v \in D_X$.

Nadomeščanje z najbližjimi sosedi

Za izbran primer z manjkajočimi vrednostmi

- 1 Poiščemo k najbližjih sosedov primera z znanimi vrednostmi
- 2 Izračunamo povprečne vrednosti spremenljivk v množici sosedov
- 3 Nadomestimo neznano vrednost X v izbranem primeru z izračunano povprečno vrednostjo X

Težava: nastavitev parametra k

Nadomeščanje z napovednimi modeli: iterativni postopek

Prva iteracija

Uporabimo enostavno metodo nadomeščanja.

Nadaljnje iteracije

- 1 Izberemo spremenljivko X (običajno izbiramo v nekem vrstnem redu)
- 2 Naučimo se napovedni model m za ciljno spremenljivko X , pri čemer so vse druge spremenljivke napovedne (zgolj primeri z znanimi vrednostmi)
- 3 Nadomestimo neznane vrednosti X z napovedmi modela m

Ustavitvena pogoja

- Maksimalno število iteracij
- Nespremenjene vrednosti spremenljivk

Algoritem TDIDT obvladuje neznane vrednosti

Razdelitev množice na osnovi spremenljivke X

- Primere z znano vrednostjo X razdelimo na osnovi vrednosti X
- Primere z neznano vrednostjo X razdelimo med **vse naslednike** vozlišča
- Proporcionalno glede na število primerov z znano vrednostjo X v vsakem nasledniku vozlišča
- Na ta način se izognemo brisanju primerov z neznano vrednostjo X in vnesemo manj predsodka v naučene modele

V čem je težava: predsodek napovednih modelov

Povečan predsodek

- Točne napovedi za pogosto opazovane vrednosti zmanjšujejo napako
- Zato so napovedi pogostih vrednosti ciljne spremenljivke pomembnejše

Klasifikacija

Pogostejše napovedovanje večinskega razreda.

Regresija

Natančnejše napovedi za pogosto opazovane vrednosti.

Rešitev: vzorčenje podatkovne množice

Podvzorčenje, *undersampling*

Iz vzorca odstranjujemo predstavnike večinskega razreda.

Prevzorčenje, *oversampling*


V vzorcu ponavljamo primere iz manjšinskega razreda.

Kaj pa v primeru regresije?

Regresija: funkcija pomembnosti

$$\phi : Y \rightarrow [0, 1]$$

- Primere z visoko pomembnostjo $\{(\mathbf{x}, y) \in S : \phi(y) > t\}$ prevzorčimo
- Primere z nizko pomembnostjo $\{(\mathbf{x}, y) \in S : \phi(y) \leq t\}$ podvzorčimo



SMOTE: osnovna ideja in parametri

SMOTE = *Synthetic Minority Over-sampling Technique*

Kombinacija prevzorčenja in podvzorčenja

- Parameter *pre*: stopnja prevzorčenja v odstotkih
- Parameter *pod*: stopnja podvzorčenja v odstotkih
- Število najbližjih sosedov k , običajno $k = 5$
- Pri izbiri brez ponavljanja naj bo $k \geq \lfloor pre/100 \rfloor$

Sintetični primeri

- Namesto ponavljanja primerov iz manjšinskega razreda
- Tvorimo nove sintetične primere

SMOTE: tvorba sintetičnih primerov

Stopnja prevzorčenja *pre*

- Za vsak primer iz manjšinskega razreda
- Ustvarimo $\lfloor pre/100 \rfloor$ sintetičnih primerov

Za vsak primer $e = (\mathbf{x}, y) \in S$ iz manjšinskega razreda

- 1 Iz množice k najbližjih sosedov primera e iz manjšinskega razreda naključno izberemo $\lfloor pre/100 \rfloor$ primerov
- 2 Za vsakega izbranega soseda $e_n = (\mathbf{x}_n, y) \in S$ ustvarimo nov primer $e_s = (\mathbf{x}_s, y)$, kjer je

$$\mathbf{x}_s = \mathbf{x} + g \cdot (\mathbf{x}_n - \mathbf{x})$$

in je g naključno število iz intervala $[0, 1]$.

SMOTE: podvzorčenje in nastavitve parametrov

Stopnja podvzorčenja *pod*

Določa koliko primerov večinskega razreda obdržimo po prevzorčenju manjšinskega razreda: pri *pod* = 100% jih obdržimo približno toliko kot v manjšinskem razredu, pri *pod* = 200% pa približno dvakrat toliko.

Običajne nastavitve parametrov

- *pre*: 100%, 200%, 300%
- *pod*: 100%, 200%
- *k*: 5

SMOTER: regresija

Manjšinski in večinski razred

- Na osnovi vrednosti funkcije pomembnosti ϕ
- Večinski razred za primere, kjer $\phi(y) \leq t$
- Manjšinski razred za ostale primere
- Lahko tudi več manjšinskih razredov glede na različne intervale vrednosti funkcije pomembnosti

Vrednost y_s za sintetične primere

$$y_s = y + g \cdot (y_n - y)$$

Algoritmi in implementacije

Manjkajoče vrednosti

- Modul `sklearn.impute`
- Razredi `SimpleImputer`, `IterativeImputer` in `KNNImputer`
- Knjižnica `MICE` v R-ju

SMOTE (Chawla in ost. 2002) in SMOTER (Torgo in ost. 2013)

- Pythonova knjižnica `imbalanced-learn`, razširitev knjižnice `sklearn`
- Knjižnici `smotefamily` in `ubl` v R-ju