

Razlaga napovednih modelov in njihovih napovedi

Ljupčo Todorovski

Univerza v Ljubljani, Fakulteta za matematiko in fiziko
Institut Jožef Stefan, Odsek za tehnologije znanja (E8)

Maj 2026

- 1 Razlaga napovedi
- 2 Metode razlage napovedi
 - LIME
 - SHAP
 - Permutacijske metode
- 3 Primerjava metod in implementacije

Kaj želimo pojasniti?

Napovedni model

$$m : D_{X_1} \times \cdots \times D_{X_p} \rightarrow D_Y$$

Za izbrani primer $\mathbf{x} = (x_1, \dots, x_p)$ nas zanima razlaga napovedi $m(\mathbf{x})$.

Lokalna razlaga

- Koliko je vsaka spremenljivka prispevala k napovedi za **izbrani primer**?
- Razlaga je običajno vektor prispevkov

$$\phi(\mathbf{x}) = (\phi_1(\mathbf{x}), \dots, \phi_p(\mathbf{x}))$$

- Pozitivni prispevki povečajo napoved, negativni jo zmanjšajo.

Tri ravni vprašanj

Lokalna razlaga posamezne napovedi

Zakaj je model m za primer $\mathbf{x}$ napovedal $m(\mathbf{x})$?

Globalna pomembnost spremenljivk

Koliko spremenljivka prispeva k napovedni moči modela m na množici S ?

Analiza napovednega modela

- Ali model m uporablja spremenljivke na smiseln način?
- Ali so razlage modela m stabilne (podobne) pri podobnih primerih?
- Ali je pomembnost spremenljivke vzročna ali zgolj napovedna?

Razlaga kot vsota prispevkov

Za regresijo

$$m(\mathbf{x}) \approx \phi_0 + \sum_{j=1}^p \phi_j(\mathbf{x}),$$

kjer je ϕ_0 osnovna napoved, $\phi_j(\mathbf{x})$ pa prispevek spremenljivke X_j .

Za klasifikacijo razlagamo verjetnost $P(Y = c \mid \mathbf{x})$ ali logaritem oboj

$$\log \frac{P(Y = c \mid \mathbf{x})}{1 - P(Y = c \mid \mathbf{x})}$$

Izbrati moramo vrednost $c \in D_Y$, za katero izračunamo prispevke.

Odsotnost spremenljivk

Ključni korak razlage

Kako definiramo napoved modela, ko poznamo zgolj vrednosti spremenljivk z indeksi iz množice $A \subseteq \{1, 2, \dots, p\}$?

Funkcija v vrednosti **koalicije** spremenljivk z indeksi iz A

$$v(A) = \mathbb{E}_{\mathbf{X}_{-A}} [m(\mathbf{x}_A, \mathbf{X}_{-A})]$$

- $\mathbf{x}_A$ so znane vrednosti nabora spremenljivk v koaliciji A
- $\mathbf{X}_{-A}$ predstavlja nabor spremenljivk z **neznanimi** vrednostmi
- Kako vzorčimo $\mathbf{X}_{-A}$?

Formalizacije odsotnosti spremenljivk

Robna (marginalna) $v(A) = \mathbb{E}_{\mathbf{X}_{-A}} [m(\mathbf{x}_A, \mathbf{X}_{-A})]$

- Ne upošteva korelacij med spremen., lahko ustvari nerealistične primere
- V praksi pogosto vzorčimo iz empirične porazdelitve $\mathbf{X}_{-A}$
- Intervencijsko: vrednosti v A nastavimo na $\mathbf{x}_A$, spremenljivke zunaj A pa vzorčimo iz izbrane referenčne porazdelitve

Pogojna $v(A) = \mathbb{E}_{\mathbf{X}_{-A} | \mathbf{x}_A} [m(\mathbf{x}_A, \mathbf{X}_{-A})]$

- Upošteva korelacije med spremenljivkami, a zahteva več informacij o porazdelitvi podatkov
- Informacija o odsotnih, a koreliranih spremenljivkah se lahko še vedno ohrani v vzorcu skozi ostale spremenljivke
- V praksi pogosto vzorčimo iz pogojne porazdelitve $\mathbf{X}_{-A} | \mathbf{x}_A = \mathbf{x}_A$

Osnovna ideja

LIME: *Local Interpretable Model-agnostic Explanations*

Okoli primera $\mathbf{x}$ zgradimo enostaven in razumljiv lokalni model g , ki računa približke napovedi osnovnega (poljubno kompleksnega) modela m .

Optimizacijski problem

$$\hat{g} = \arg \min_{g \in G} \mathcal{L}(m, g, \pi_{\mathbf{x}}) + \Omega(g)$$

- G je družina razumljivih modelov, pogosto so to linearni modeli
- $\pi_{\mathbf{x}}(\mathbf{z})$ meri podobnost $\mathbf{z}$ s transformirano predstavitvijo $\mathbf{z}_0$ izhodiščnega primera $\mathbf{x}$
- $\Omega(g)$ je kompleksnost modela, zagotavlja kratke in razumljive razlage

Transformacija primerov

Od izhodiščnega do motenih primerov

- Izhodiščni primer $\mathbf{x}$ pretvorimo v nov, razlagalni prostor: $\mathbf{x} \mapsto \mathbf{z}_0$
- Predstavitve $\mathbf{z}_i \in \{0, 1\}^d$ dobimo z naključnim spreminjanjem komponent v $\mathbf{z}_0$
- $\mathbf{z}_i$ pretvorimo nazaj v ustrezen primer $\mathbf{x}_i$, primeren za m
- $z_{ij} = 1$ pomeni, da je komponenta j v primeru $\mathbf{z}_i$ prisotna

Primeri motenj

- Besedila: izklopljene besede odstranimo iz dokumenta
- Slike: izklopljene (super-)piksle zakrijemo ali nadomestimo
- Tabele: izklopljene vrednosti nadomestimo z vzorčenjem iz empirične porazdelitve

Izpeljava utežene linearne razlage

Lokalni linearni model

$$g(\mathbf{z}) = w_0 + \sum_{j=1}^d w_j z_j$$

Utežena kvadratna izguba

Za motene transformirane primere $\{\mathbf{z}_i\}_{i=1}^N$ in ustrezne primere v izhodiščnem prostoru $\{\mathbf{x}_i\}_{i=1}^N$:

$$\mathcal{L}(m, g, \pi_{\mathbf{x}}) = \sum_{i=1}^N \pi_{\mathbf{x}}(\mathbf{z}_i) (m(\mathbf{x}_i) - g(\mathbf{z}_i))^2$$

Rešitev linearne razlage z matrikami

Oznake

- Z je matrika transformiranih primerov z dodatnim stolpcem enic
- $\hat{\mathbf{y}}$ je vektor napovedi $[m(\mathbf{x}_1) \ m(\mathbf{x}_2) \ \dots \ m(\mathbf{x}_N)]^T$
- W je diagonalna matrika $\text{diag}(\pi_{\mathbf{x}}(\mathbf{z}_1), \dots, \pi_{\mathbf{x}}(\mathbf{z}_N))$

Brez kazni kompleksnosti

$$\begin{aligned} J(\mathbf{w}) &= (\hat{\mathbf{y}} - Z\mathbf{w})^T W (\hat{\mathbf{y}} - Z\mathbf{w}) \\ \nabla J(\mathbf{w}) &= -2Z^T W (\hat{\mathbf{y}} - Z\mathbf{w}) = 0 \\ \hat{\mathbf{w}} &= (Z^T W Z)^{-1} Z^T W \hat{\mathbf{y}} \end{aligned}$$

Izbira mer podobnosti in kompleksnosti

Mera podobnosti

Pogosta izbira je Gaussovo jedro

$$\pi_{\mathbf{x}}(\mathbf{z}_i) = \exp\left(-\frac{D(\mathbf{z}_0, \mathbf{z}_i)^2}{\sigma^2}\right)$$

kjer D meri razdaljo med transformiranimi predstavitevama in σ določa širino jedra.

Kazen za kompleksnost razlagalnega modela g

- Lasso: $\Omega(g) = \lambda \sum_j |w_j|$
- Omejitev števila spremenljivk: $\|\mathbf{w}\|_0 \leq K$
- Razlaga napovedi: največji $|w_j|$ so lokalno najpomembnejši

Prednosti, slabosti, uporaba

Prednosti

- Deluje s poljubnim modelom, potrebujemo zgolj napovedi $m(\mathbf{x}_i)$
- Razlage so kratke, lokalne in pogosto intuitivne
- Posebej uporaben za besedila in slike z razlagalnimi komponentami

Slabosti

- Razlaga je občutljiva na način vzorčenja motenj primerov in širino jedra
- Novi primeri so lahko nerealistični, kar vodi do nezanesljivih razlag
- Nenatančen lokalni približek pri močnih korelacijah in interakcijah

Agregacija lokalnih razlag

Lokalni prispevki za posamezne primere $\mathbf{x}_i \in S$

$$\hat{\mathbf{w}}(\mathbf{x}_i) = (\hat{w}_{i1}, \dots, \hat{w}_{id})$$

Globalna pomembnost komponente

$$I_j^{LIME} = \frac{1}{n} \sum_{i=1}^n |\hat{w}_{ij}|$$

Običajna agregacija je povprečna absolutna lokalna utež.

Razlaga globalne pomembnosti

Velik I_j^{LIME} pomeni, da se komponenta j pogosto pojavlja kot močna lokalna razlaga napovedi.

Razlaga kot kooperativna igra

Igra spremenljivk za izbrani primer $\mathbf{x}$

- Igralci so spremenljivke z indeksi iz množice $\mathcal{F} = \{1, \dots, p\}$
- Koalicija $A \subseteq \mathcal{F}$ vsebuje spremenljivke, katerih vrednosti $\mathbf{x}_A$ poznamo
- Vrednost koalicije $v(A)$ je napoved, ko vrednosti zunaj A nadomestimo po izbrani formalizaciji

Razlaga kot vsota prispevkov

$$m(\mathbf{x}) = \phi_0 + \sum_{j=1}^p \phi_j(\mathbf{x})$$

kjer je $\phi_0 = v(\emptyset)$ in $\sum_j \phi_j(\mathbf{x}) = v(\mathcal{F}) - v(\emptyset)$.

Shapleyjeva vrednost

Prispevek spremenljivke j k koaliciji A

$$\Delta_j(A) = v(A \cup \{j\}) - v(A)$$

Shapleyjeva vrednost spremenljivke j

$$\phi_j(\mathbf{x}) = \sum_{A \subseteq \mathcal{F} \setminus \{j\}} \frac{|A|!(p - |A| - 1)!}{p!} \Delta_j(A)$$

Pomen uteži

Koalicije z enako velikostjo $|A|$ imajo skupno utež $1/p$, vse koalicije iste velikosti so enako verjetne.

Izpeljava iz naključnih permutacij

Permutacijska interpretacija

Naj bo Π množica vseh $p!$ vrstnih redov spremenljivk. Za permutacijo $\pi \in \Pi$ naj bo P_j^π množica spremenljivk, ki so pred spremenljivko X_j .

Povprečni mejni prispevek

$$\phi_j(\mathbf{x}) = \frac{1}{p!} \sum_{\pi \in \Pi} (v(P_j^\pi \cup \{j\}) - v(P_j^\pi))$$

Če je A fiksna, vnaprej določena koalicija spremenljivk, je število permutacij z $P_j^\pi = A$ enako $|A|!(p - |A| - 1)!$.

Zakaj je formula enolična?

Aksiomi

- Učinkovitost:

$$\sum_j \phi_j(\mathbf{x}) = v(\mathcal{F}) - v(\emptyset)$$

- Simetrija: enako prispevajoče spremenljivke dobijo enako vrednost.
- Ničelni igralec: če je $\Delta_j(A) = 0$ za vse A , potem je $\phi_j(\mathbf{x}) = 0$.
- Aditivnost: za $v = v_1 + v_2$ velja $\phi_j(v) = \phi_j(v_1) + \phi_j(v_2)$.

Dokažemo lahko, da je Shapleyjeva vrednost edina funkcija prispevkov, ki zadošča tem aksiomom.

Alternativni izračun: jedrna utežena regresija

Predstavitev koalicije z binarnim vektorjem $\mathbf{z} \in \{0, 1\}^p$

$$A(\mathbf{z}) = \{j : z_j = 1\}, \quad g(\mathbf{z}) = \phi_0 + \sum_{j=1}^p \phi_j z_j$$

Rešimo uteženo regresijo nad vzorčenimi koalicijami

$$\arg \min_{\phi_0, \phi} \sum_{\mathbf{z} \in \{0, 1\}^p : 0 < |\mathbf{z}| < p} \pi(\mathbf{z}) (v(A(\mathbf{z})) - g(\mathbf{z}))^2$$

$$\pi(\mathbf{z}) = \frac{p-1}{\binom{p}{|\mathbf{z}|} |\mathbf{z}| (p - |\mathbf{z}|)} \quad \text{za } 0 < |\mathbf{z}| < p$$

Koaliciji $\emptyset$ in $\mathcal{F}$ določita osnovno in polno napoved.

Primer za dve spremenljivki

Množica spremenljivk $\mathcal{F} = \{1, 2\}$

$$\begin{aligned}\phi_1(\mathbf{x}) &= \frac{1}{2} (v(\{1\}) - v(\emptyset)) + \frac{1}{2} (v(\{1, 2\}) - v(\{2\})) \\ \phi_2(\mathbf{x}) &= \frac{1}{2} (v(\{2\}) - v(\emptyset)) + \frac{1}{2} (v(\{1, 2\}) - v(\{1\}))\end{aligned}$$

Vsak prispevek je povprečje učinka, ko spremenljivko dodamo pred in po drugi spremenljivki.

Prednosti, slabosti, uporaba

Prednosti

- Jasno matematično ozadje in enoličnost pri Shapleyjevih aksiomih
- Prispevki se seštevajo v razliko med napovedjo in osnovno napovedjo
- Učinkovita različica TreeSHAP za drevesne modele in ansamble dreves

Slabosti

- Točen izračun je eksponenten v številu spremenljivk
- Rezultati so odvisni od izbire funkcije $v(A)$ in vzorcev, ki jih uporabljamo za oceno $v(A)$
 - Robna formalizacija lahko ustvari nerealistične primere
 - Pogojna formalizacija zahteva več informacij o porazdelitvi podatkov
 - Intervencijska je podobna marginalni, a z drugačno interpretacijo
- Prispevki koreliranih spremenljivkah so lahko zavajajoči

Agregacija lokalnih razlag

Lokalni prispevki za posamezne primere $\mathbf{x}_i \in S$

$$\phi(\mathbf{x}_i) = (\phi_1(\mathbf{x}_i), \dots, \phi_p(\mathbf{x}_i))$$

Globalna pomembnost, po analogiji z LIME

$$I_j^{SHAP} = \frac{1}{n} \sum_{i=1}^n |\phi_j(\mathbf{x}_i)|$$

Dodatni agregaciji za globalno pomembnost

- $\frac{1}{n} \sum_i \phi_j(\mathbf{x}_i)$: povprečna smer vpliva
- Porazdelitev $\phi_j(\mathbf{x}_i)$: heterogenost in interakcije

Permutacijska razlaga posamezne napovedi

Ideja

Spremenljivko X_j odstranimo tako, da njene vrednosti nadomestimo z vrednostmi iz podatkovnega vzorca.

Lokalni učinek spremenljivke

$$\delta_j(\mathbf{x}) = m(\mathbf{x}) - \frac{1}{r} \sum_{k=1}^r m(x_1, \dots, x_{j-1}, b_{kj}, x_{j+1}, \dots, x_p)$$

$B = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_r\}$ je vzorec podatkovne množice.

Če je $\delta_j(\mathbf{x}) > 0$, vrednost $X_j = x_j$ poveča napoved glede na njeno naključno nadomestitev.

Permutacijske metode: izpeljava iz pričakovanja

Robna (marginalna) odsotnost spremenljivke

$$v_{-j}(\mathbf{x}) = \mathbb{E}_{X_j} [m(\mathbf{x}_{-j}, X_j)]$$

Prispevek ocenimo kot

$$\delta_j(\mathbf{x}) = m(\mathbf{x}) - v_{-j}(\mathbf{x})$$

Monte Carlo ocena

Če $b_{1j}, \dots, b_{rj}$ vzorčimo iz empirične porazdelitve X_j , potem

$$\hat{v}_{-j}(\mathbf{x}) = \frac{1}{r} \sum_{k=1}^r m(\mathbf{x}_{-j}, b_{kj}) \rightarrow v_{-j}(\mathbf{x})$$

Permutacijske metode: globalna pomembnost

Osnovni rezultat modela

Naj bo $p(m, S)$ mera kakovosti modela m na množici S .

Permutacijska pomembnost

Za permutacijo stolpca X_j označimo spremenjeno množico z S^{π_j} .

$$I_j^{PFI} = p(m, S) - \mathbb{E}_{\pi_j} [p(m, S^{\pi_j})]$$

Ocena z R ponovitvami

$$\hat{I}_j^{PFI} = p(m, S) - \frac{1}{R} \sum_{r=1}^R p(m, S^{\pi_{jr}})$$

Permutacijska pomembnost za izgubo

Če uporabljamo izgubo

$$L(m, S) = \frac{1}{n} \sum_{i=1}^n \ell(y_i, m(\mathbf{x}_i))$$

Manjša vrednost pomeni boljši model.

Pomembnost na osnovi povečanja izgube

$$I_j^{PFI} = \mathbb{E}_{\pi_j} [L(m, S^{\pi_j})] - L(m, S)$$

Isto kot pri zmanjševanju kakovosti: predznak je prilagojen smeri mere.

Permutacijske metode: povezava lokalnega in globalnega

Agregacija lokalnih permutacijskih učinkov

$$I_j^{local-perm} = \frac{1}{n} \sum_{i=1}^n |\delta_j(\mathbf{x}_i)|$$

Razlika do globalne permutacijske pomembnosti

- $I_j^{local-perm}$ meri spremembo napovedi
- I_j^{PFI} meri spremembo napovedne kakovosti glede na Y
- Zato je I_j^{PFI} bližje pojmu **napovedne moči** spremenljivke

Permutacijske metode: prednosti, slabosti, uporaba

Prednosti

- Modelno neodvisne in enostavne za implementacijo
- Neposredno merijo padec kakovosti modela
- Naravna izbira za oceno globalne napovedne moči spremenljivk

Slabosti

- Pri koreliranih spremenljivkah lahko podcenijo pomembnost
- Permutacije ustvarijo nerealistične kombinacije vrednosti
- Za lokalne razlage nimamo aditivne dekompozicije napovedi

Primerjava metod

LIME

Lokalna aproksimacija modela; dobro za kratke, intuitivne razlage.

SHAP

Predstavitev napovedi kot vsote prispevkov; dobro, ko želimo konsistentnost in primerljivost prispevkov.

Permutacijske metode

Odstranitev informacije s permutacijo; najbolj neposredna globalna mera napovednih moči spremenljivk.

Primerjava agregiranih pomembnosti

Kaj agregiramo?

- LIME: lokalne koeficiente razlagalnega modela
- SHAP: Shapleyjeve prispevke k napovedi
- Permutacije: spremembo napovedi ali spremembo kakovosti modela

Tipične formule

$$I_j^{LIME} = \frac{1}{n} \sum_i |\hat{w}_{ij}|$$

$$I_j^{SHAP} = \frac{1}{n} \sum_i |\phi_j(\mathbf{x}_i)|$$

$$I_j^{PFI} = s(m, S) - \frac{1}{R} \sum_r s(m, S^{\pi_{jr}})$$

Kdaj uporabimo katero metodo?

Lokalno pojasnjevanje posamezne odločitve

- LIME: ko potrebujemo kratko razlago iz razlagalnih komponent
- SHAP: ko potrebujemo aditivne in med primeri primerljive prispevke
- Lokalne permutacije: ko nas zanima občutljivost napovedi na konkretno vrednost spremenljivke

Globalna pomembnost

- Permutacijska pomembnost je najbližja vprašanju: koliko model izgubi brez informacije v X_j ?
- Agregirani SHAP je najbližji vprašanju: koliko X_j običajno prispeva k napovedim?

Pogoste pasti pri razlagi modelov

Korelirane spremenljivke

- Razlaga lahko razdeli pomembnost med nadomestne spremenljivke
- Permutacija ene spremenljivke lahko ustvari nerealistične primere

Razlaga ni vzročni učinek

Velik prispevek pomeni, da model uporablja informacijo, ne pa nujno, da bi sprememba vrednosti spremenljivke povzročila spremembo vrednosti ciljne spremenljivke.

Razlagamo model, ne sveta

Dobra razlaga slabega modela je lahko natančen opis napačnega sklepanja!

Implementacije v scikit-learn

Neposredno implementirano

- `sklearn.inspection.permutation_importance`
- Globalna permutacijska pomembnost spremenljivk
- Deluje s poljubno oceno poljubne kakovosti modela, `scoring`

Ni neposredno implementirano v scikit-learn

- LIME: običajno uporabimo paket `lime`
- SHAP: običajno uporabimo paket `shap`
- Lokalne permutacijske razlage: sestavimo z večkratnim klicem `predict` ali `predict_proba`.