

Uvod v predmet in strojno učenje

Ljupčo Todorovski



Univerza v Ljubljani, Fakulteta za matematiko in fiziko
Institut Jožef Stefan, Odsek za tehnologije znanja (E8)

Februar 2026


Razpoznavanje števk



Izbiranje (optimalnih) potez v igrah



John Snow, London 1854



Vzorci: Skupine okužb



Hipoteze in modeli: Bližina vodnih virov



Terminologija strojnega učenja in podatkovne analize

Podatki

- Seznam smrtnih primerov (pacientov dr. Snowa) in njihovih lokacij
- Lokacije vodnih črpalk

Vzorci

Skupine smrtnih primerov v nekaj delih mesta

Hipoteza

Skupine primerov lokacijsko povezane z izbranimi vodnimi črpalkami

Terminologija strojnega učenja in podatkovne analize

Napovedni model

- Smrtni primeri najbolj pogosti v bližini vodne črpalke na ulici Broad
- Vhodni podatek je lokacija bivališča, napoved verjetnost preživetja

Odločitev

Zapreti vodno črpalko na ulici Broad

Cilji strojnega učenja in podatkovne analize

Strojna analiza podatkov usmerjena v

- 1 Iskanje **zanimivih** vzorcev v podatkih
- 2 Gradnjo **točnih** in **splošnih** napovednih modelov

Uporabnost vzorcev in modelov

Boljše razumevanje podatkov

- Kratka in nazorna predstavitev podatkov
- Vzpostavitev lokacijske povezave med okužbami in vodnimi črpalkami

Pojasnjevanje in napovedovanje

- Voda kot vir oziroma medij za prenašanje bolezni
- Uporabniki vode iz črpalke na ulici Broad bodo zboleli

Odločanje in ukrepanje

- Zapiranje vodne črpalke na ulici Broad za zajezitev epidemije
- Pasterizacija vode za preprečevanje izbruha novih epidemij

Pregled predavanja

- 1 Motivacija
- 2 Formalne definicije
 - Podatki, modeli in vzorci
 - Izguba in napaka napovednega modela
 - Naloga in algoritem strojnega učenja
- 3 Osrednji težavi strojnega učenja
 - Pretirano prilaganje učnim podatkom
 - Prekletstvo večrazsežnosti, *Curse of Dimensionality*
- 4 Izvedba predmeta in pravila igre
 - Pregled vsebine predmeta
 - Ocena pri predmetu
 - Vodič po programski opremi in literaturi

Spremenljivke in njihovi tipi

Spremenljivka X z domeno (množico možnih vrednosti) D_X je lahko

- **numerična**, če je $D_X \subseteq \mathbb{R}$ in so torej možne vrednosti X urejene
- **diskretna**, če je D_X končna množica in so vrednosti X neurejene

Dvojiška (**binarna**) spremenljivka

- Poseben podtip diskretne spremenljivke, kjer velja $|D_X| = 2$
- Običajni domene $D_X = \{0, 1\}$, $D_X = \{-1, 1\}$ ali $D_X = \{\ominus, \oplus\}$

Podatkovna množica za nadzorovano učenje

Spremenljivke

- Urejena p -terica **napovednih spremenljivk** $\mathbf{X} = \langle X_1, X_2, \dots, X_p \rangle$
- Z domenami $D_{X_1}, D_{X_2}, \dots, D_{X_p}$; p imenujemo **razsežnost** pod. množice
- **Ciljna spremenljivka** Y z domeno D_Y

Primer e je urejna dvojica oziroma $(p + 1)$ -terica $\langle \mathbf{x}, y \rangle = \langle x_1, x_2, \dots, x_p, y \rangle$

- x_i je vrednost napovedne spremenljivke X_i , torej $x_i \in D_{X_i}$
- y je vrednost ciljne spremenljivke, torej $y \in D_Y$

Iz **podatkovne množice** primerov $S \subseteq D_{X_1} \times \dots \times D_{X_p} \times D_Y$ se želimo naučiti **napovedovati** vrednost Y na osnovi podanih vrednosti $\mathbf{X}$.

Podatkovna množica za nenadzorovano učenje

Razlika z nadzorovanim učenjem, glej prejšnjo prosojnico

- Ni ciljne spremenljivke Y
- Primer je p -terica oblike $e = \mathbf{x} = \langle x_1, x_2, \dots, x_p \rangle$
- Podatkovna množica je $S \subseteq D_{X_1} \times D_{X_2} \times \dots \times D_{X_p}$

V podatkovni množici primerov $S \subseteq D_{X_1} \times D_{X_2} \times \dots \times D_{X_p}$

- Želimo odkrivati vzorce, ki so lahko različnih oblik, na primer,
- Podmnožice primerov, ki so si medsebojno podobni
- Vrednosti spremenljivk, ki se pogosto pojavljajo skupaj

Ilustrativni primer: Kartica zvestobe

Primeri (vrstice) so nakupovalci, spremenljivke (stolpci) njihove lastnosti

Ime	Prihodki	Starost	Spol	Letna poraba	Dober nakupovalec
Mojca	1,890	32	Ž	18,200	da
Janez	1,200	48	M	8,900	ne
Špela	900	63	Ž	9,200	da

Primeri so nakupi, spremenljivke nakupovalec in produkti

Nakupovalec	Spol	Pivo	Plenice	Voda	Kruh	Čokolada
Mojca	Ž	0	0	0	2	3
Janez	M	2	2	0	1	0

Napovedni model

Je preslikava $m: D_{X_1} \times D_{X_2} \times \dots \times D_{X_p} \rightarrow D_Y$

- Za podane vrednosti $\mathbf{x} = \langle x_1, x_2, \dots, x_p \rangle$ napovednih spremenljivk $\mathbf{X}$
- Izračuna napoved $\hat{y} = m(\mathbf{x})$ vrednosti ciljne spremenljivke Y

Dva tipa napovednih modelov

- **Regresijski** napoveduje vrednosti **numerične** ciljne spremenljivke
- **Klasifikacijski** napoveduje vrednosti **diskretne** ciljne spremenljivke

Naloga nadzorovanega učenja

Za podan nabor spremenljivk $\mathbf{X} = \langle X_1, X_2, \dots, X_p \rangle$ in Y označimo

- **Prostor podatkov**, potenčna množica $\mathcal{D} = 2^{D_{X_1} \times D_{X_2} \times \dots \times D_{X_p} \times D_Y}$
- **Prostor modelov**, množica preslikav $\mathcal{M} = D_Y^{D_{X_1} \times D_{X_2} \times \dots \times D_{X_p}}$

Algoritem nadzorovanega učenja je preslikava iz $\mathcal{D}$ v $\mathcal{M}$

- Za podano množico išče **najbolj točen in najbolj splošen model**
- Kako merimo točnost in splošnost napovednega modela?

Izguba napovednega modela

Funkcija izgube $L: D_Y \times D_Y \rightarrow \mathbb{R}_{\geq 0}$

- Izračuna **napako** ene napovedi $\hat{y}$ glede na opazovano vrednost y
- Izguba $L(y, \hat{y}) = 0$ natanko takrat, ko $y = \hat{y}$, sicer je pozitivna

Običajna funkcija izgube za regresijske modele

$$L_{SE}(y, \hat{y}) = (y - \hat{y})^2$$

Kvadratna izguba, *Squared Error*, *SE*

- Manj pogosto uporabljena alternativa je $L_{AE}(y, \hat{y}) = |y - \hat{y}|$
- Izogibamo se jo zaradi težav z zvezno odvedljivostjo

Običajna funkcija izgube za klasifikacijske modele

$$L_{01}(y, \hat{y}) = \mathbb{1}(y \neq \hat{y}) = \begin{cases} 1 & \text{če } y \neq \hat{y} \\ 0 & \text{če } y = \hat{y} \end{cases}$$

Izbuba 01

Uporabljamo jo, ko je D_Y množica neurejenih diskretnih vrednosti.

Napovedna napaka modela na podatkovni množici S

$$\text{Error}(m, S) = \frac{1}{|S|} \sum_{\langle \mathbf{x}, y \rangle \in S} L(y, m(\mathbf{x}))$$

Je povprečna izguba modela m na primerih iz S

- Meri napako modela m na podatkovni množici S
- $\text{Error}: \mathcal{M} \times \mathcal{D} \rightarrow \mathbb{R}_{\geq 0}$ slika iz prostora podatkov $\mathcal{D}$ in modelov $\mathcal{M}$
- Glej prosojnico 17

Naloga nadzorovanega učenja (bolj formalno)

Za podano podatkovno množico S iz podatkovnega prostora $\mathcal{D}$ najdi

- **Točen model** $m \in \mathcal{M}$ z minimalno napako $\text{Error}(m, S)$
- **Splošen model** m , ki ima točne napovedi $m(\mathbf{x})$ za $\langle \mathbf{x}, \cdot \rangle \notin S$

Splošnost modela

- Je napaka modela na **testni** množici primerov S_{test}
- Učna in testna množica sta tuji (disjunktni), torej $S \cap S_{\text{test}} = \emptyset$
- Učno množico pogosto (da ne bo nesporazumov) označimo S_{train}

Algoritem strojnega učenja $\mathcal{A}$

Za nadzorovano učenje (tudi napovedno modeliranje), $\mathcal{A}: \mathcal{D} \rightarrow \mathcal{M}$

Iz podane učne množice S_{train} algoritem $\mathcal{A}$ izračuna model $m = \mathcal{A}(S_{train})$ za napovedovanje vrednosti ciljne spremenljivke Y iz podanih vrednosti napovednih spremenljivk $X_1, X_2, \dots, X_p$.

Za nenadzorovano učenje $\mathcal{A}: \mathcal{D} \rightarrow \mathcal{P}$, $\mathcal{P}$ je prostor vzorcev

V podani učni množici S_{train} (brez ciljne spremenljivke) algoritem $\mathcal{A}$ odriva vzorce oziroma množice

- Podobnih primerov
- Vrednosti spremenljivk, ki se pogosto pojavljajo skupaj

Primeri modelov in vzorcev: Kartica zvestobe

Napovedni modeli

- klasifikacijski, Dober nakupovalec = $m(\text{Starost}, \text{Prihdoki}, \text{Spol})$
- regresijski, Letna poraba = $m(\text{Starost}, \text{Spol})$

Vzorci

- Skupine nakupovalcev s podobnimi nakupi
- Moški, ki kupijo plenice, kupijo tudi pivo

Osrednji težavi strojnega učenja

Optimalen in nepristranski napovedni model

Minimizira pričakovano kvadratno napako $E[(Y - m(\mathbf{X}))^2]$:

$$m(\mathbf{x}) = E[Y | \mathbf{X} = \mathbf{x}]$$

Približek tega modela na učni množici S_{train} :

$$m(\mathbf{x}_0) = \frac{1}{|S_0|} \sum_{\langle \mathbf{x}, y \rangle \in S_0} y, \quad S_0 = \{\langle \mathbf{x}_0, y \rangle \in S_{train}\}$$

- Oцени pričakovano vrednost Y kot njeno povprečno vrednost
- Na podmnožici učnih primerov $\langle \mathbf{x}, y \rangle \in S_{train}$ za katere velja $\mathbf{x} = \mathbf{x}_0$

Problem: Množica S_0 bo pogosto **prazna** ali pa imela **(pre)malo primerov**.

Rešitev: Najbližji sosedi in soseščina

$$S_0 = \{\langle \mathbf{x}, \cdot \rangle \in S_{train} : \forall \langle \mathbf{x}', \cdot \rangle \in S_{train} \setminus S_0 : \|\mathbf{x} - \mathbf{x}_0\| \leq \|\mathbf{x}' - \mathbf{x}_0\|\}$$

$$|S_0| = k$$

Spremenili smo definicijo množice S_0

- Množico S_0 poimenujemo tudi **soseščina** točke $\mathbf{x}_0$
- Vedno vsebuje k primerov, ki so **najbližji** primeru $\mathbf{x}_0$

Premisli kakšna je napaka optimalnega modela na S_{train} za $k = 1$?

Umetni podatkovni množici

Numerične spremenljivke


- 10 napovednih spremenljivk $X_1, \dots, X_{10}$, $D_{X_i} = [0, 1]$
- Ciljna spremenljivka Y , $D_Y = \mathbb{R}$

Model $Y = (-X_1 - 0.5X_2 + 0.5X_4 + X_5)^2 + \mathcal{N}(0, 0.05)$

- Vrednosti napovednih spremenljivk naključno vzorčimo
- Vrednostim Y dodamo Gaussov šum porazdeljen po $\mathcal{N}(0, 0.05)$
- Večina napovednih spremenljivk $X_3, X_6, X_7, X_8, X_9, X_{10}$ je odvečnih, saj ne vplivajo na vrednost ciljne spremenljivke Y


Vzorčili smo dve množici, **učno** in **testno**, vsaka ima 100 primerov.

Vpliv k na točnost in splošnost modela




Težava: Najbolj točen model ni tudi najbolj splošen!

Preprileganje, *overfitting* in podprileganje, *underfitting*





- Preprileganje: model je točen, a premalo splošen, je preveč kompleksen
- Podprileganje: model ni ne točen ne splošen, je preveč enostaven

Vpliv razsežnosti na točnost in splošnost za $k = 6$




Večja razsežnost množice, slabša točnost in splošnost modela: Zakaj?

Polmer soseščine za $k = 10$ pri eni in dveh dimenzijah



Polmer naraste iz 0.07 na 0.19: Kaj pri večjih razsežnostih?

Vpliv razsežnosti na polmer sosesčine za $k = 10$



Težava: Z večanjem razsežnosti sosesčina zajame ves podatkovni prostor!

Ključna vprašanja strojnega učenja in tega predmeta

Kako izbrati napovedni model?

Ki je prav kompleksen, točen in splošen.

Kako nasloviti prekletstvo večrazasežnosti?

Da jih ni ne preveč ne premalo.

Kako različni algoritmi strojnega učenja naslovijo ta dva vprašanja?

Izvedba predmeta in pravila igre

Prvi del: Algoritmi strojnega učenja

Nadzorovano učenje

- Linearni modeli in najbližji sosed
- Odločitvena drevesa in pravila
- Ansambli napovednih modelov
- Metode podpornih vektorjev in jedrne funkcije
- Nevronske mreže
- Vrednotenje in izbira napovednega modela

Nenadzorovano učenje

- Razvrščanje v skupine

Drugi del: Praktična podatkovna analiza

- Proces podatkovne analize s strojnim učenjem
- Izbira in konstrukcija napovednih spremenljivk
- Manjkajoči podatki
- Neenakomerna porazdelitev vrednosti ciljne spremenljivke
- Besedilni podatki in vložitve, *embeddings*

Ocenjevanje, pogoji in roki

Ocena iz vaj: Domači in seminarska naloga

- Dve domači nalogi, vsaka prinese največ 30 točk
- Roka za oddajo domačih nalog marca in aprila
- Projekt analize podane podatkovne množice, največ 40 točk
- Rok za oddajo seminarske naloge bo na začetku izpitnega obdobja

Ustni izpit

- Pogoj za pristop: več kot 50 točk iz vaj
- Za uspešno opravljen ustni izpit: doseženih več kot 50 točk

scikit-learn in Orange za ljubitelje Pythona

scikit-learn: knjižnica algoritmov za strojno učenje

- scikit-learn.org, uporabljali ga bomo na vajah
- Prednost: Strojno učenje z uporabo normalnega programskega jezika
- Slabost: Ni podpore diskretnim spremenljivkam, (vedno manj) omejen nabor implementiranih algoritmov

Orange: Odprto-kodna programska oprema za strojno učenje

- orange.biolab.si, razvit na UL-FRI, ne bo ga na vajah
- Prednost: Vizualno programiranje delotokov za obdelavo podatkov od priprave do gradnje in vrednotenja ter primerjave modelov
- Slabost: Relativno omejen nabor razpoložljivih metod, ni možnosti nalaganja zunanjih implementacij algoritmov

caret za ljubitelje R

Prosto-dostopno programsko okolje za statistiko

- Prednost: na voljo imate impresivni nabor orodij za statistične obdelave podatkov in vizualizacijo
- Slabost: »čudno« bogat in slabo koceptualiziran programski jezik

Številni paketi za strojno učenje

- caret: Classification and Regression Training, primerjava modelov
- randomForest, kernlab, neuralnet: Različne metode strojnega učenja
- tm: Text Mining, Obravnava besedilnih podatkov

Weka za ljubitelje Java

Odprto-kodna knjižnica algoritmov za strojno učenje

- www.cs.waikato.ac.nz/ml/weka/, ne boste ga spoznali na vajah
- Prednost: Impresivno število implementiranih algoritmov, neposredna povezljivost s podatkovnimi bazami (JDBC)
- Slabost: Počasne implementacije, nenavaden uporabniški vmesnik

Dobro (a zastarelo) izhodišče za razvoj novih metod

- Zelo hitra in enostavna primerjava z (tako rekoč vsemi) obstoječimi
- Dobra podpora in velika skupnost uporabnikov
- Podprta s knjigo, ki pa ni prosto dostopna (glej naprej)

Vodič po literaturi (1)

An Introduction to Statistical Learning

- Prosti dostop na www.statlearning.com
- Spletne stran ponuja tudi dostop do spletnih tečajev, priporočam tistega od Hastie in Tibshirani
- Obvezno branje: Pokriva večino snovi predmeta

The Elements of Statistical Learning

- Prosti dostop na web.stanford.edu/~hastie/ElemStatLearn
- Za tiste, ki imate radi teorijo in matematično ozadje algoritmov
- Kakšna snov bo pokrita le v tem učbeniku, pregled v spletni učilnici

Vodič po literaturi (2)

Data Mining: Practical Machine Learning Tools and Techniques

- Za ljubitelje prakse
- Referenčni vir za izkušene analitike: Lahko na hitro preverite delovanje algoritma strojnega učenja in nastavitve parametrov

Machine Learning: The Art and Science of Algs that Make Sense of Data

Odličen kompromis med teorijo in prakso.

Applied Predictive Modeling

- Za eksperte praktične podatkovne analize
- Zahtevni primeri uporabe, koristni triki v programskem orodju R, vodič po uporabi paketa caret