

Vrednotenje in izbira napovednih modelov

Ljupčo Todorovski


Univerza v Ljubljani, Fakulteta za matematiko in fiziko
Institut Jožef Stefan, Odsek za tehnologije znanja (E8)

Februar 2026

Pregled predavanja



- 1 Pristranskost in varianca
 - Teoretična izpeljava
 - Razumevanje dekompozicije in posledice
- 2 Vredotenje napovedne napake
 - Prečno preverjanje
 - Zankanje
 - Izбира napovednega modela
- 3 Prostor ROC za dvojiško klasifikacijo
 - Slabovidnost napovedne napake in točnosti
 - Krivulja ROC in ploščina pod njo
- 4 Mere napake za regresijske modele

Primer podatkovne množice, $p = 1$, $D_{X_1} \subseteq \mathbb{R}$, $D_Y \subseteq \mathbb{R}$





Vprašanje: linearni ali oscilacijski model?

Izbira linearnega modela, *William of Ockham*




Izbira oscilacijskega modela, testni podatki



Prostora modelov




Prostor linearnih modelov in podatki



- Male spremembe naklona premice zelo spremenijo napako modela
- Učenje modela je **zelo stabilno** in robustno glede spremembe podatkov
- Rečemo tudi, da je **varianca** modela pri spremembi podatkov **nizka**

Prostor oscilacijskih modelov in podatki




- Spremembe amplitude oscilacije ne vplivajo bistveno na napako modela
- Učenje modela je **zelo nestabilno** in občutljivo na spremembe podatkov
- Rečemo tudi, da je **varianca** modela pri spremembi podatkov **visoka**

Prostora modelov in podatki




Kompromis med pristranskostjo in varianco

Predsodek = pristranskost (angl. *bias*)



Nevarna posledica: napačna izbira modela



Pravi model

Predpostavimo obstoj pravega, determinističnega modela za podatke

$$y = m(\mathbf{x}) + \epsilon$$

ϵ je šum v podatkih, velja $\mathbb{E}[\epsilon] = 0$.

Naj bo $\mathbf{x}_0$ vektor podanih vrednosti napovednih spr., potem velja

- ① $\mathbb{E}[m(\mathbf{x}_0)] = m(\mathbf{x}_0)$, ker je m determinističen
- ② $\mathbb{E}[Y|\mathbf{X} = \mathbf{x}_0] = \mathbb{E}[m(\mathbf{x}_0) + \epsilon] \stackrel{[1]}{=} m(\mathbf{x}_0)$
- ③ $\text{Var}[Y|\mathbf{X} = \mathbf{x}_0] = \mathbb{E}[(Y - \mathbb{E}[Y])^2|\mathbf{X} = \mathbf{x}_0] \stackrel{[2]}{=} \mathbb{E}[\epsilon^2] = \sigma_\epsilon^2$
- ④ $\mathbb{E}[Y^2|\mathbf{X} = \mathbf{x}_0] = \text{Var}[Y|\mathbf{X} = \mathbf{x}_0] + \mathbb{E}[Y|\mathbf{X} = \mathbf{x}_0]^2 \stackrel{[2,3]}{=} m(\mathbf{x}_0)^2 + \sigma_\epsilon^2$

Naučeni napovedni model $\hat{m}$

Predpostavimo, da imamo na voljo veliko različnih učnih množic S

- Na vsaki množici se naučimo napovedni model $\hat{m}$
- Kaj lahko povemo o pričakovani napaki teh modelov pri $\mathbf{X} = \mathbf{x}_0$?
- Računali bomo torej $\mathbb{E}_S[\text{Error}(\mathbf{x}_0)] = \mathbb{E}_S[(Y - \hat{m}(\mathbf{x}_0))^2 | \mathbf{X} = \mathbf{x}_0]$

Ker za varianco velja $\text{Var}[U] = \mathbb{E}[U^2] - \mathbb{E}[U]^2$, velja tudi

$$\textcircled{1} \quad \mathbb{E}_S[\hat{m}(\mathbf{x}_0)^2] = \text{Var}_S[\hat{m}(\mathbf{x}_0)] + \mathbb{E}_S[\hat{m}(\mathbf{x}_0)]^2$$

Dekompozicija pričakovane napake napovednih modelov

$$\mathbb{E}_S[\text{Error}(\mathbf{x}_0)]$$

$$= \mathbb{E}_S[(Y - \hat{m}(\mathbf{x}_0))^2 | \mathbf{X} = \mathbf{x}_0]$$

$$= \mathbb{E}_S[Y^2 + \hat{m}(\mathbf{x}_0)^2 - 2Y\hat{m}(\mathbf{x}_0) | \mathbf{X} = \mathbf{x}_0]$$

$$= \mathbb{E}_S[Y^2 | X = \mathbf{x}_0] + \mathbb{E}_S[\hat{m}(\mathbf{x}_0)^2] - 2\mathbb{E}_S[Y\hat{m}(\mathbf{x}_0) | \mathbf{X} = \mathbf{x}_0]$$

$$[m2, m4] = m(\mathbf{x}_0)^2 + \sigma_\epsilon^2 + \mathbb{E}_S[\hat{m}(\mathbf{x}_0)^2] - 2m(\mathbf{x}_0)\mathbb{E}_S[\hat{m}(\mathbf{x}_0)]$$

$$[\hat{m}1] = \sigma_\epsilon^2 + m(\mathbf{x}_0)^2 + \mathbb{E}_S[\hat{m}(\mathbf{x}_0)]^2 + \text{Var}_S[\hat{m}(\mathbf{x}_0)] - 2m(\mathbf{x}_0)\mathbb{E}_S[\hat{m}(\mathbf{x}_0)]$$

$$= \sigma_\epsilon^2 + (m(\mathbf{x}_0) - \mathbb{E}_S[\hat{m}(\mathbf{x}_0)])^2 + \text{Var}_S[\hat{m}(\mathbf{x}_0)]$$

$$= \sigma_\epsilon^2 + \text{Pristranskost} + \text{Varianca}$$

Tri komponente napovedne napake

σ_ϵ^2 je komponenta podatkovnega šuma

Na to komponento strojno učenje nima vpliva.


Pristranskost $(m(\mathbf{x}_0) - \mathbb{E}_S[\hat{m}(\mathbf{x}_0)])^2$

- Razlika med pričakovano vrednostjo napovedi in pravo vrednostjo Y
- Pove nam koliko se lahko modeli $\hat{m}$ približajo dejanskemu modelu m


Varianca $\text{Var}_S[\hat{m}(\mathbf{x}_0)]$

- Varianca napovedi modelov okoli pričakovane vrednosti $\mathbb{E}_S[\hat{m}(\mathbf{x}_0)]$
- Pove nam kako stabilni so modeli $\hat{m}$

Pristranskost in varianca: grafična ponazoritev



Kompromis med pristranskostjo in varianco



Prileganje, pristranskost in varianca

Preprileganje, *overfitting*

- Situacija, ko se soočamo z **nizko pristranskostjo** in **visoko varianco**
- Kompleksen prostor modelov: **najbližji sosedi z malim k**
- Desna polovica grafa na prejšnji prosojnci



Podprileganje, *underfitting*

- Situacija, ko se soočamo z **visoko pristranskostjo** in **nizko varianco**
- Enostaven prostor modelov: **linearni** ali **najbližji sosedi z velikim k**
- Leva polovica grafa na prejšnji prosojnci



Pristranskost in varianca algoritma strojnega učenja

Nizka pristranskost

Visoka pristranskost



Nizka varianca



Visoka varianca

Kontrola nad pristranskostjo in varianco

Zmanjševanje pristranskosti

- Linearni modeli: dodajanje nelinearnih členov
- Najbližji sosed: zmanjševanje števila sosedov

Zmanjševanje variance

- Linearni modeli skoraj nikoli nimajo težav z visoko varianco
- Najbližji sosed: povečevanje števila sosedov in izbira nap. spremenljivk
- Splošni pristopi: regularizacija in ansambli modelov

Zmanjševanje pristranskosti povečuje varianco in obratno: zato pozorno vrednotenje in primerjanje napovedne napake za različne modele

Vrednotenje napovedne napake

Točnost in splošnost modela

Učna napaka: napaka m izmerjena na učni množici S

$$\text{Error}_{\text{train}}(m, S) = \mathbb{E}[L(y, m(\mathbf{x})) \mid \langle \mathbf{x}, y \rangle \in S] = \frac{1}{|S|} \sum_{\langle \mathbf{x}, y \rangle \in S} L(y, m(\mathbf{x}))$$

Optimistična, izmerjena na primerih uporabljenih za učenje modela.

Testna napaka: napaka m ocenjena na primerih izven S

$$\text{Error}_{\text{test}}(m, S) = \mathbb{E}[L(y, m(\mathbf{x})) \mid \langle \mathbf{x}, y \rangle \notin S]$$

Realna, izmerjena na primerih, ki niso bili uporabljeni za učenje modela.

V obeh primerih je $L: D_Y \times D_Y \rightarrow \mathbb{R}_0^+$ funkcija izgube.

Teoretični rezultati o optimizmu učne napake

$$o = \text{Error}_{\text{test}} - \text{Error}_{\text{train}}$$

Najbolj splošen rezultat

$$\mathbb{E}[o] = \frac{2}{|S|} \sum_{(\mathbf{x}, y) \in S} \text{Cov}(m(\mathbf{x}), y)$$

Optimizem je obratno sorazmeren številu učnih primerov $|S|$.

Rezultat za linearne modele $\text{Cov}(m(\mathbf{x}), y) = p \sigma_{\epsilon}^2$

Optimizem je premo sorazmeren številu napovednih spremenljivk p .

Praktičen pristop

Različne metode za ocenjevanje napake na testnih primerih

- Naključna izbira testnih primerov iz učne množice
- Prečno preverjanje, *cross-validation*
- Zankanje, *bootstrapping*

Razbitje učne množice S

$$S_{test} \subset S$$

$$S_{train} = S \setminus S_{test}$$

Vzorečenje učnih primerov v S_{test} iz S brez ponavljanja

- Parameter d določa delež testnih primerov, $d = |S_{test}|/|S|$
- Ker je $S_{train} = S \setminus S_{test}$, potem očitno $S_{train} \cap S_{test} = \emptyset$
- Problem: **velika občutljivost ocene napake** na izbiro primerov

Rešitev za nižanje občutljivosti: večkratno vzorčenje

Dva pristopa večkratnega vzorčenja

- Prečno preverjanje
- Zankanje

Razbitje učne množice S

$$S = \bigcup_{i=1}^k S_i$$

$$\forall i \neq j : S_i \cap S_j = \emptyset, |S_i| \approx |S_j|$$

k podmnožic $S_i : i = 1, 2, \dots, k$, k -kratno prečno preverjanje

- *Stratifikacija velikosti*: vse množice približno enako št. elementov
- *Stratifikacija porazdelitve*: vsaka množica S_i ima približno enako porazdelitev ciljne spremenljivke kot S

Od razbitja do ocene napake

Za vsako $S_i, i = 1, 2, \dots, k$ izvedemo dva koraka

- 1 Naučimo se napovedni model m_i na primerih iz $S_{train} = S \setminus S_i$
- 2 Izmerimo napako modela m_i na primerih iz $S_{test} = S_i$

Ocena napovedne napake Error_{CV}

$$\text{Error}_{CV}(S) = \frac{1}{k} \sum_{i=1}^k \text{Error}(m_i, S_i)$$

Kako izberemo vrednost k ?

Običajni vrednosti k : 5 ali 10

- Izbira odvisna od števila primerov v podatkovni množici S
- Za množice z vsaj 10,000 primeri izberemo $k = 10$, sicer $k = 5$
- Pozor: oznaka k običajno uporabljena pri prečnem preverjanju se »tepe« s tisto za število najbližjih sosedov

Izpusti enega, *leave-one-out*, LOO, za $k = |S|$

- Poseben primer prečnega preverjanja brez naključnega vzorčenja
- Zelo drago, učni algoritem moramo pognati $|S|$ krat
- Ocena pristranska in optimistična, saj je večina primerov učnih

Vzorčenje učne množice S

B vzorcev $V_i: i = 1, 2, \dots, B$ množice S

- Vse V_i imajo enako kardinalnost $|V_i| = |S|$, vzorčenje s ponavljanjem
- V_i bodo imele vlogo učnih, $S \setminus V_i$ pa testnih množic

Kakšna je verjetnost, da primer e ostane izven učne množice?

$$P(e \notin V_i) = (1 - 1/|S|)^{|S|}$$

- $\lim_{|S| \rightarrow \infty} P(e \notin V_i) = 1/e$, približno 0.368
- Torej je delež učnih primerov približno $1 - 0.368 = 0.632$

Od vzorčenja do ocene napake

Za vsak V_i , $i = 1, 2, \dots, B$ izvedemo dva koraka

- 1 Naučimo se napovedni model m_i na primerih iz $S_{train} = V_i$
- 2 Izmerimo napako modela m_i na množici $S_{test} = S \setminus V_i$

Dve oceni napovedne napake Error_{BS}

$$\text{Error}_{BS}(S) = \frac{1}{B} \sum_{i=1}^B \text{Error}(m_i, S \setminus V_i)$$

$$\text{Error}_{BS632}(S) = 0.368 \text{Error}_{train}(S) + 0.632 \text{Error}_{BS}(S)$$

Izbira optimalnega modela m za podano množico S

Za podano podatkovno množico S izberemo

- Nabor algoritmov $\mathcal{A}_1, \mathcal{A}_2, \dots, \mathcal{A}_q$ za strojno učenje
- Za vsak $\mathcal{A}_i$ izberemo nabor nastavitev parametrov $N_{i,1}, N_{i,2}, \dots, N_{i,r_i}$

Za vsako dvojico $(\mathcal{A}_i, N_{i,j})$

- 1 Uporabimo vzorčenje množice S za oceno napake $\text{Error}_{i,j}$
- 2 Ugotovimo pri kateri dvojici dosežemo minimalno napako Error
- 3 Uporabimo to dvojico za gradnjo končnega modela m na množici S

Izbira algoritmov in nastavitev

Faktorji, ki vplivajo na izbiro algoritma

- Lastnosti podatkovne množice: $|S|$, p , problemsko področje
- Lastnosti dobljenih modelov: pojasnjevanje, točnost ali splošnost

Katere nastavitve parametrov algoritma?

- Parametri in vrednosti, ki bistveno spreminjajo kompleksnost modela
- Torej bistveno vplivajo na odnos med pristranskostjo in varianco

Priporočila za enostavne modele


Linearni modeli

- Manjša pristranskost: nelinearne kombinacije napovednih spremenljivk
- Manjša varianca: izbira podmnožice vhodnih spremenljivk
- Manjša varianca: regularizacija


Najbližji sosedi

- Manjša pristranskost: manjše število sosedov k
- Manjša varianca: izbira podmnožice vhodnih spremenljivk


Izbira regresijskega modela kNN s CV-5



Izbira regresijskega modela kNN z BS-50



Izbira regresijskega modela kNN s TT-0.75



Prostor ROC za dvojiško klasifikacijo

Naloga klasifikacije s ciljno spremenljivko $Y : D_Y = \{-1, 1\}$

Klasifikacija (razvrščanje) v dva razreda

- razred **negativnih** primerov: $Y = -1$, tudi $Y = 0$ ali $Y = \ominus$
- razred **pozitivnih** primerov: $Y = 1$, tudi $Y = \oplus$

Dve vrsti klasifikacijskih modelov

- Napoved razreda Y , $m: D_{X_1} \times D_{X_2} \times \cdots \times D_{X_p} \rightarrow \{-1, 1\}$
- Napoved verjetnosti $P(Y = 1)$, $m: D_{X_1} \times D_{X_2} \times \cdots \times D_{X_p} \rightarrow [0, 1]$

Dve vrsti napak

Običajna napaka za funkcijo izgube $L_{01}(y, \hat{y}) = \mathbb{1}(y \neq \hat{y})$

$$\text{Error}(m, S) = \frac{1}{S} \sum_{\langle \mathbf{x}, y \rangle \in S} L_{01}(y, m(\mathbf{x}))$$

- Uporabna zgolj za modele, ki napovedujejo razred (in ne verjetnosti)
- Ne loči med dvema vrstama napak spodaj

Vrsti napak binarne klasifikacije

- 1 lažni pozitivni primer, *false positive*, *FP*
- 2 lažni negativni primer, *false negative*, *FN*

Tabela napačnih klasifikacij, *confusion matrix*

	$Y = 1$	$Y = 0$
$\hat{Y} = 1$	pravilno razvrščeni pozitivni primeri <i>true positives, TP</i>	lažni pozitivni primeri <i>false positives, FP</i>
$\hat{Y} = 0$	lažni negativni primeri <i>false negatives, FN</i>	pravilno razvrščeni negativni primeri <i>true negatives, TN</i>
Σ	pozitivni primeri, n_+	negativni primeri, n_-

$$n_+ = TP + FN, n_- = FP + TN, n = n_+ + n_- = TP + FN + FP + TN$$

Tabela napačnih klasifikacij, napovedna napaka in točnost

Napovedna napaka

$$Err = \frac{FP + FN}{n}$$

Idealni model $Err = 0$.

Napovedna točnost, *accuracy*

$$Acc = \frac{TP + TN}{n} = 1 - Err$$

Idealni model $Acc = 1$.

Niti ena od teh mer ne loči med napakami FP in FN .

Trije enako točni modeli: $Err = 0.3, Acc = 0.7$

$$|S| = n = 100, n_+ = 50, n_- = 50$$

	m_1		m_2		m_3	
$\hat{Y} = 1$	50	30	20	0	35	15
$\hat{Y} = 0$	0	20	30	50	15	35

Dva pristranska in nepristranski model

- ① m_1 je »optimističen«, napove 80% pozitivnih primerov
- ② m_2 je »pesimističen«, napove 20% pozitivnih primerov
- ③ m_3 je »nepristranski«, napove 50% pozitivnih primerov; prav tak je delež pozitivnih primerov v množici S

Bolj občutljivi meri: občutljivost, TPR in izpad, FPR

Delež pravilno razvrščenih pozitivnih primerov, *True Positive Rate*, TPR

$$TPR = \frac{TP}{n_+}$$

- Tudi občutljivost, senzitivnost, *sensitivity*, priklic, *recall*
- Točnost v množici pozitivnih primerov, idealni model $TPR = 1$

Delež napačno razvrščenih negativnih primerov, *False Positive Rate*, FPR

$$FPR = \frac{FP}{n_-} = 1 - \frac{TN}{n_-}$$

- $1 - \text{specifičnost}$, $1 - \text{specificity}$, izpad, *fall out*
- Napaka v množici negativnih primerov, idealni model $FPR = 0$

Trije enako točni modeli: $Err = 0.3, Acc = 0.7$

$$|S| = n = 100, n_+ = 50, n_- = 50$$


	m_1		m_2		m_3	
$\hat{Y} = 1$	50	30	20	0	35	15
$\hat{Y} = 0$	0	20	30	50	15	35

Bolj občutljivi meri TPR in FPR

Model	TPR		FPR	
m_1	50/50 =	1.0	30/50 =	0.6
m_2	20/50 =	0.4	0/50 =	0.0
m_3	35/50 =	0.7	15/50 =	0.3

FPR (x-os) in TPR (y-os) razpenjata prostor ROC

ROC = *Receiver Operating Characteristic*



Izbira modela in cenovno-občutljiva klasifikacija

Kako izbrati med m_1 , m_2 in m_3 ?


- Če sta napaki tipa FP in FN enakovredni, so trije modeli enakovredni
- Kaj pa, če napaki nista enakovredni?

Cenovno-občutljiva binarna klasifikacija: matrika cen (uteži) napak

	$Y = 1$	$Y = 0$
$\hat{Y} = 1$	0	2
$\hat{Y} = 0$	1	0


- Napaka tipa FP je 2 krat »hujša« kot napaka tipa FN
- Kateri model izberemo v tem primeru?

Izbira modela m_2 pri $FP : FN = 2 : 1$



»Pesimistični« model izbiramo na osnovi izpada oz. specifičnosti, FPR .

Izbira modela m_1 pri $FP : FN = 1 : 2$



»Optimistični« model izbiramo na osnovi občutljivosti, TPR .

Napovedovanje verjetnosti in prag odločitve

Napovedni model za verjetnost pozitivnega razreda

$$m(\mathbf{x}) = P(Y = 1|X = \mathbf{x})$$

Za napoved razreda rabimo še prag $\theta \in [0, 1]$

$$\hat{Y}_\theta = \mathbb{1}(m(\mathbf{x}) \geq \theta)$$

Običajni izbor $\theta = 0.5$.

Kako izberemo optimalno vrednost θ ?

Narišemo modele za vse možne vrednosti θ v prostoru ROC.

Izračun krivulje ROC za model m in osem primerov


X	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	TPR	FPR
Y	0	0	1	1	0	0	1	1		
$m(X)$	0.0	0.1	0.3	0.3	0.3	0.4	0.7	0.9		
$\hat{Y}_{\theta=1.0}$	0	0	0	0	0	0	0	0	0.00	0.00
$\hat{Y}_{\theta=0.9}$	0	0	0	0	0	0	0	1	0.25	0.00
$\hat{Y}_{\theta=0.7}$	0	0	0	0	0	0	1	1	0.50	0.00
$\hat{Y}_{\theta=0.4}$	0	0	0	0	0	1	1	1	0.50	0.25
$\hat{Y}_{\theta=0.3}$	0	0	1	1	1	1	1	1	1.00	0.50
$\hat{Y}_{\theta=0.1}$	0	1	1	1	1	1	1	1	1.00	0.75
$\hat{Y}_{\theta=0.0}$	1	1	1	1	1	1	1	1	1.00	1.00

Izračun posameznih točk krivulje ROC

X	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
Y	0	0	1	1	0	0	1	1
$m(X)$	0.0	0.1	0.3	0.3	0.3	0.4	0.7	0.9


	$\theta = 1.0$		$\theta = 0.9$		$\theta = 0.4$		$\theta = 0.3$	
$\hat{Y} = 1$	0	0	1	0	2	1	4	2
$\hat{Y} = 0$	4	4	3	4	2	3	0	2
	0.00	0.00	0.25	0.00	0.50	0.25	1.00	0.50

Krivulja ROC za model m



Krivulja ROC za idealni model m^*

X	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
Y	0	0	0	0	1	1	1	1
$m^*(X)$	0.1	0.2	0.3	0.3	0.7	0.7	0.8	0.9



Krivulja ROC je monotono (in ne strogo) naraščajoča

Če zmanjšujemo vrednost θ

- Narašča število napovedi $\hat{Y} = 1$, torej $TP + FP$
- n_+ in n_- sta konstantni, narašča tudi $TPR + FPR = TP/n_+ + FP/n_-$

Ker sta TPR in FPR nenegativni se lahko zgodi troje

- 1 Vertikalni segment: poveča se le TPR
- 2 Horizontalni segment: poveča se le FPR
- 3 Poševni segment: povečata se hkrati TPR in FPR

AUC: Ploščina pod krivuljo ROC

$$AUC(m) = \int_0^1 FPR(m_{\Theta}) TPR(m_{\Theta}) d\Theta$$

Mera točnosti modela, ki napoveduje verjetnost

- Mera **ne zahteva vnaprejšnje odločitve o vrednosti praga θ**
- Omogoča primerjavo točnosti modelov, ki napovedujejo verjetnost

Vrednosti AUC na intervalu $[0, 1]$:

- 1: model, ki idealno loči pozitivne od negativnih primerov
- 0.5: naključni model
- 0: model, ki tudi idealno loči pozitivne od negativnih primerov, a vse pozitivne primere razglasi za negativne in obratno

Interpretacija AUC in krivulj ROC

Kaj pove AUC ?

$$AUC(m) = P(m(\mathbf{x}_+) > m(\mathbf{x}_-))$$

- $\langle \mathbf{x}_+, 1 \rangle$ in $\langle \mathbf{x}_-, 0 \rangle$ sta naključno izbrana pozitiven in negativen primer
- Ocena razdalje med verjetnostmi za pozitivne in negativne primere

Česa AUC ne pove?

- Ne ponuja jasne interpretacije ekspertu s področja uporabe
- Veliki del ploščine »nezanimiv« zaradi nedopustno visokega FPR
- Zato raje **krivulje ROC primerjamo vizualno**

Preciznost modela, *precision*, *positive predictive value*, *PPV*

$$PPV = \frac{TP}{TP + FP}$$

- Delež pozitivno razvrščenih primerov, ki so dejansko pozitivni
- Verjetnost, da je pozitivna napoved pravilna, idealni model $PPV = 1$

Pogosto jo opazujemo skupaj s priklicem oz. $TPR = TP/n_+$

- Tudi občutljivost, senзитivnost, *sensitivity*, priklic, *recall*
- Točnost v množici pozitivnih primerov, idealni model $TPR = 1$

Mera F, harmonična sredina preciznosti in priklica

$$F = \frac{2}{\frac{1}{PPV} + \frac{1}{TPR}} = 2 \frac{PPV \cdot TPR}{PPV + TPR}$$

- Večje vrednosti ustrezajo boljšim modelom
- Največja vrednost je 1, takrat ko sta preciznosti in priklic 1

Mere napake za regresijske modele

Normalizirana celotna napaka

$$\text{ReRMSE} = \sqrt{\frac{\sum_{\langle \mathbf{x}, y \rangle \in S} (y - \hat{y})^2}{\sum_{\langle \mathbf{x}, y \rangle \in S} (y - \bar{y})^2}} = \frac{\sqrt{\frac{1}{|S|} \sum_{\langle \mathbf{x}, y \rangle \in S} (y - \hat{y})^2}}{\sqrt{\frac{1}{|S|} \sum_{\langle \mathbf{x}, y \rangle \in S} (y - \bar{y})^2}}$$

- Manjše vrednosti ustrezajo boljšim modelom
- Vrednost 1 pomeni, da je napaka modela enaka napaki modela, ki napoveduje povprečno vrednost Y na učni množici
- Neodvisna od velikostnega razreda vrednosti Y

Pojasnjena varianca

$$EV = \frac{\text{Var}[Y - \hat{Y}]}{\text{Var}[Y]}$$

- Manjše vrednosti ustrezajo boljšim modelom
- Ne zazna sistematičnih napak v napovedih (ker meri le varianco)

Implementacija v scikit-learn

Izbira modela in vrednotenje napake

- Modul `sklearn.model_selection`
- Funkciji `cross_val_score` in `cross_validate`, različni iteratorji
- Razred za zankanje `sklearn.cross_validation.Bootstrap`

Vrednotenje modelov

- Modul `sklearn.metrics`
- Različne funkcije, npr. `roc_curve`, `accuracy_score`, `root_mean_squared_error` ali `r2_score`