

Ansambli napovednih modelov

Ljupčo Todorovski

Univerza v Ljubljani, Fakulteta za matematiko in fiziko
Institut Jožef Stefan, Odsek za tehnologije znanja (E8)

Marec 2026

- 1 Osnovna ideja in definicije
- 2 Homogeni, vzporedni ansambli
 - Pristranskost in varianca homogenih ansamblov
 - Vrečenje, *bagging*
 - Naključni pod-prostori in gozdovi
 - Razlaga naključnega gozda in relevantnost spremenljivk
- 3 Druge vrste ansamblov

Osnovna ideja

Namesto enega, se naučimo več napovednih modelov


- 1 Tako, da spreminjamo učno podatkovno množico
- 2 Tako, da uporabimo različne algoritme strojnega učenja

S kombiniranjem njihovih napovedi lahko zmanjšamo varianco in s tem tudi napovedno napako.


Kompromis med pristranskostjo in varianco



Možna posledica: napačna izbira modela



Ansambel namesto izbire enega modela



Struktura ansambla in osnovna notacija

Osnovni modeli $\hat{m}_t, t = 1, 2, \dots, T$, tudi elementi ansambla $\hat{M}$

- Vsi $\hat{m}_t$ napovedujejo vrednost ciljne spremenljivke Y , $\hat{m}_t: \cdot \rightarrow D_Y$
- Napoved modela $\hat{m}_t$ na podanem primeru $\mathbf{x}$ označimo z $\hat{y}_t = \hat{m}_t(\mathbf{x})$

Funkcija C_M za komb. napovedi elementov v napoved ansambla $\hat{y} = \hat{M}(\mathbf{x})$

$$C_M: \underbrace{D_Y \times \dots \times D_Y}_{T \text{ krat}} \rightarrow D_Y$$

- Razvrščanje: modus, $\hat{y}$, ki se največkrat pojavi v $\{\hat{y}_t: t = 1, 2, \dots, T\}$
- Regresija: povprečje, $\hat{y} = \sum_{t=1}^T \hat{y}_t / T$

Predpostavka: neodvisni osnovni modeli

Vsakemu osnovnemu modelu $\hat{m}_t$ pripišemo naključno spremenljivko Z_t

$$Z_t = \mathbb{1}(y \neq \hat{y}_t), \quad Z_t: \begin{pmatrix} 0/y = \hat{y}_t & 1/y \neq \hat{y}_t \\ 1 - \epsilon & \epsilon \end{pmatrix}$$

$0 \leq \mathbb{E}[Z_t] = \epsilon \leq \frac{1}{2}$ je pričakovana napovedna napaka osnovnih modelov.

Zanima nas pričakovana napaka ansambla $Error(\hat{M}) = P(\hat{y} \neq y)$

- $\hat{y} \neq y$ natanko takrat, ko $\sum_{t=1}^T Z_t > T/2$
- Napoved ansambla $\hat{y}$ je napačna (torej različna od opazovane vrednosti y), če so napovedi več kot polovice osnovnih modelov napačne

Pričakovana napaka ansambla neodvisnih modelov


$$Error(M) = P\left(\sum_{t=1}^T Z_t > \frac{T}{2}\right)$$

$$\begin{aligned}\{\mathbb{E}[Z_t] = \epsilon\} &= P\left(\sum_{t=1}^T (Z_t - \mathbb{E}[Z_t]) > \frac{T}{2} - T\epsilon\right) \\ &= P\left(\frac{1}{T} \sum_{t=1}^T (Z_t - \mathbb{E}[Z_t]) > \frac{1}{2} - \epsilon\right)\end{aligned}$$

$$\left\{ \text{Hoeffdingova neenakost, } 0 \leq \epsilon \leq \frac{1}{2} \right\} \leq \exp\left(-2T\left(\frac{1}{2} - \epsilon\right)^2\right)$$

Torej: pričakovana napaka ansambla neodvisnih osnovnih modelov pada eksponentno z naraščanjem velikosti ansambla T .

Velikost ansambla in pričakovana napaka



Heterogeni in homogeni ansambli

Tipologija ansamblov glede **načina učenja osnovnih modelov**.

Homogeni ansambli

- Vsi osnovni modeli naučeni z **istim algoritmom**
- Vsak osnovni model naučen iz **spremenjene** učne množice

Heterogeni ansambli

- Osnovni modeli naučeni z **različnimi algoritmi**
- Običajno vsi osnovni modeli naučeni iz **iste** učne množice

Vzporedni in zaporedni ansamblji

Tipologija ansambllov glede **medsebojne odvisnosti njihovih elementov**.

Vzporedni ansamblji

- Vsak osnovni model naučen **neodvisno** od vseh drugih
- Osnovne modele **lahko učimo vzporedno**

Zaporedni ansamblji

- Naslednji osnovni model naučen **v odvisnosti** od prejšnjih
- Osnovne modele **moramo učiti zaporedno**

Spomnimo se: Tri komponente napovedne napake

σ_ϵ^2 je komponenta podatkovnega šuma

Na to komponento strojno učenje nima vpliva.

Pristranskost $(m(\mathbf{x}_0) - \mathbb{E}_S[\hat{m}(\mathbf{x}_0)])^2$

- Razlika med pričakovano vrednostjo napovedi in pravo vrednostjo Y
- Pove nam koliko se lahko modeli $\hat{m}$ približajo dejanskemu modelu m

Varianca $\text{Var}_S[\hat{m}(\mathbf{x}_0)]$

- Varianca napovedi modelov okoli pričakovane vrednosti $\mathbb{E}_S[\hat{m}(\mathbf{x}_0)]$
- Pove nam kako stabilni so modeli $\hat{m}$

Dekompozicija napake za homogene ansamble

σ_ϵ^2 je fiksna komponenta

Ta komponenta ostane nespremenjena tudi pri homogenem ansamblu.

Pristranskost ansambla je enaka pristranskosti osnovnega modela

$$(\mathbb{E}_S[\hat{M}(\mathbf{x}_0)] - m(\mathbf{x}_0))^2 = (\mathbb{E}_S[\hat{m}(\mathbf{x}_0)] - m(\mathbf{x}_0))^2$$

Izpeljava na tabli.

Faktor zmanjševanja variance homogenega ansambla

$$\text{Var}_S[\hat{M}(\mathbf{x}_0)] = \left(\rho(\mathbf{x}_0) + \frac{1 - \rho(\mathbf{x}_0)}{T} \right) \text{Var}_S[\hat{m}(\mathbf{x}_0)]$$

$\rho(\mathbf{x}_0)$ je korelacija med napovedmi osnovnih modelov, izpeljava na tabli.

Faktor zmanjševanja variance

$$\rho + \frac{1 - \rho}{T}$$

Če je korelacija ρ blizu 1

- Se faktor zmanjševanja variance približa ρ , torej 1
- **Raznovrstnost napovedi** elementov **zmanjšuje** varianco ansambla

Če je korelacija ρ blizu 0

- Se faktor zmanjševanja variance približuje $1/T$
- **Velikost ansambla** T **zmanjšuje** njegovo varianco

Homogeni ansambl:

Vrečenje, naključni prostori in naključni gozdovi

Učenje osnovnih modelov $\hat{m}_t = \mathcal{A}(V_t)$

T vzorcev $V_t, t = 1, 2, \dots, T$ učne množice S

- Vsi vzorci enake velikosti $V_t: |V_t| = |S|$, vzorčenje s ponavljanjem
- Na vseh vzorcih V_t uporabimo isti algoritem $\mathcal{A}$

Spomnimo se: verjetnost, da izbran primer e ostane izven vzorca

$$P(e \notin V_t) = (1 - 1/|S|)^{|S|}$$
$$\lim_{|S| \rightarrow \infty} P(e \notin V_t) = 1/e \approx 0.368$$

Napovedi izven vreče, *out-of-bag*, OOB

Napoved OOB za podan primer $e = \langle \mathbf{x}, y \rangle$


$$\hat{y}_{OOB} = C_M(\hat{y}_{t_1}, \hat{y}_{t_2}, \dots, \hat{y}_{t_s}) = C_M(m_{t_1}(\mathbf{x}), m_{t_2}(\mathbf{x}), \dots, m_{t_s}(\mathbf{x}))$$

- $\hat{y}_{t_i}$ je napoved osnovnega modela m_{t_i} za $\mathbf{x}$
- Za vse $t_i, i = 1, 2, \dots, s$ velja $e \notin V_{t_i}$, upoštevamo torej napovedi modelov, naučenih iz **učnih množic, ki ne vsebujejo e**


Ocena napake OOB za množico primerov S

$$Error_{OOB}(\hat{M}, S) = \frac{1}{|S|} \sum_{\langle \mathbf{x}, y \rangle \in S} L(\hat{y}_{OOB}, y)$$


Klasifikacija z vrečenjem: ocena s prečnim preverjanjem




Klasifikacija z vrečenjem: ocena OOB



Regresija z vrečenjem: ocena s prečnim preverjanjem



Regresija z vrečenjem: ocena OOB



Naključni pod-prostori, *random subspaces*

Učenje osnovnih modelov $\hat{m}_t = \mathcal{A}(V_t)$

- Učna množica z naključno izbranim vzorcem napovednih spremenljivk $V_{\mathbf{X}} \subseteq \mathbf{X} = \{X_1, X_2, \dots, X_p\}$, vzorčenje **brez ponavljanja**
- $V_t = S|_{V_{\mathbf{X}}}$ je vzorec S , ki vsebuje le spremenljivke iz $V_{\mathbf{X}}$
- Parameter je velikost vzorcev $q = |V_{\mathbf{X}}|$, $q < p$, običajno $q \ll p$

Kaj pa ocena napake OOB?

Ker ni vzorčenja primerov, ni na voljo napovedi OOB.

Naključni gozd, *random forest*

Kombinacija metod vrečenja in naključnih pod-prostorov

- $\hat{m}_t$ je odločitveno drevo, običajno naučeno brez rezanja
- Iz V_t , vzorca učnih primerov velikosti $|S|$, kot pri vrečenju
- V vsakem koraku TDIDT optimalni test izberemo iz naključnega vzorca $q \leq p$ napovednih spremenljivk
- $q = p$ navadno vrečenje, $q = 1$ naključna izbira spremenljivke za test

Osnovni modeli bolj medsebojno različni kot pri vrečenju

- Če ima ena spremenljivka X veliko napovedno moč, bodo drevesa osnovnih modelov pri vrečenju medsebojno zelo podobna
- Pri naključnem gozdu pa ne, saj bomo lahko imeli drevesa brez X

Kontrola pristranskosti in variance


Velikost ansambla: število osnovnih modelov T


- Več osnovnih modelov, manj variance ob nespremenjeni pristranskosti
- Torej T nastavimo na čim višjo vrednost

Parameter q : velikost vzroca spremenljivk za izbiro testa


- Ni jasne, analitične povezave med vrednostjo q in varianco
- Privzeta vrednost $q = \lfloor \sqrt{p} \rfloor$; izberemo z opazovanjem napake OOB
- Običajna imena parametra q : *mtry* ali *max_features*


Klasifikacija z NG: Parameter *mtry*, prečno preverjanje



Klasifikacija z NG: T , $mtry = 2$, OOB

Regresija z NG: Parameter *mtry*, prečno preverjanje



Regresija z NG: T , $mtry = 10$, OOB

Razlaga napovedi ansambla

Razlagalna moč napovednega modela

- Ansambli ne ponujajo razumljive razlage napovedi
- Za razliko od odločitvenega drevesa ali seznama pravil
- Za razliko od linearne regresije: predznaki in vrednosti parametrov nakazujejo **napovedno moč** spremenljivk

Možna razlaga ansambla: **napovedna moč** spremenljivk

Povprečno zmanjševanje točnosti


Opazujmo razliko $D = \text{Error}(M_P, S) - \text{Error}(M, S)$ med napakami modelov

- M , ki smo ga zgradili iz učne množice S_{train}
- M_P , ki smo ga zgradili iz učne množice S'_{train} : vrednosti spremenljivke X v S'_{train} so naključna permutacija vrednosti X v S_{train}
- $\text{Error}(M_P, S)$ je torej napaka modela, kjer je vpliv spr. X izničen

Vrednost razlike D je povečanje napake (in zmanjševanje točnosti)

- Visoka, če ima X **visoko** napovedno moč
- Nizka, če ima X **nizko** napovedno moč

Regresija z NG: napovedna moč spremenljivk



Druge vrste ansamblov

Homogen, zaporeden: Pospeševanje, *boosting*

- Zgradimo m_1 na učni množici S
- Ponavljamo $T - 1$ krat: za $t = 2, 3, \dots, T$
 - Opazuj napako ansambla do sedaj zgrajenih modelov na primerih iz S
 - Vzorči S s ponavljanjem: primeri z visoko napako bolj zastopani v V
 - $m_t = \mathcal{A}(V)$
 - Namesto vzorčenja, spreminjanje uteži učnih primerov

Vzorčenje primerov ne popolnoma naključno: Pospeševanje se osredotoča na učne primere, kjer ima trenutni ansambel visoko napovedno napako.

Kompromis med pristranskostjo in varianco

Povečanje velikosti ansambla T

- Lahko zapelje posepševanje k preprileganju
- Zato pozorno opazovanje učne in testne napake pri naraščajočem T

Nastavitev parametrov osnovnega algoritma $\mathcal{A}$

- Pospeševanje **lahko zmanjša pristranskost** osnovnih modelov
- Zato izberemo osnovni algoritem z visoko pristranskostjo
- Majhna, sproti porezana odločitvena drevesa ali linearne modele

Heterogeni: Kopičenje, *Stacking*

Učenje osnovnih modelov

- Različni algoritmi, ista podatkovna množica
- Napovedi osnovnih modelov na tesnih podatkih (prečno preverjanje)
- Tako dobljene napovedi postanejo nove napovedne spremenljivke ($\mathbf{X}'$)

Kombiniranje napovedi osnovnih modelov

$$C_M = \mathcal{A}(S')$$

- Novim spremenljivkam $\mathbf{X}'$ dodamo ciljno spremenljivko Y in tako dobimo učno množico S'
- Funkcija kombinacije C_M je napovedni model naučen iz S'

Znani algoritmi in implementacije

Boosting (Schapire 1990) in AdaBoost (Freund and Schapire 1996)

Kako iz slabih napovednih modelov zgraditi dobre?

Vrečenje oz. bagging (Breiman 1994)

Kako zmanjšati varianco odločitvenih dreves?

Naključni gozd (Breiman 2001)

- Kombinacija vrečenja z idejami naključnih pod-prostorov
- Paket ranger v R-ju

Implementacija v scikit-learn

Modul `sklearn.ensemble`

Vrečenje in naključni gozdovi

- Razreda `BaggingClassifier` in `BaggingRegressor`
- Razreda `RandomForestClassifier` in `RandomForestRegressor`

Pospeševanje

Več razredov, glej npr. `GradientBoostingClassifier` in `GradientBoostingRegressor` ali pa `AdaBoostClassifier`