

Metoda podpornih vektorjev in jedrne funkcije

Ljupčo Todorovski

Univerza v Ljubljani, Fakulteta za matematiko in fiziko
Institut Jožef Stefan, Odsek za tehnologije znanja (E8)

Marec 2026


- 1 Metoda podpornih vektorjev (*Support Vector Machines*)
 - Maksimizacija roba (*margin*) in njegova optimizacija
 - Podporni vektorji
 - Linearno neločljivi podatki in regresija
- 2 Jedrne funkcije, jedra (*kernels*)
 - Transformacije prostora in definicija jedra
 - Izbira jedra

Klasifikacija kot optimizacijski problem

Linearni modeli za binarno klasifikacijo, $D_Y = \{-1, 1\}$

$$\hat{y} = g(\beta^T \mathbf{x} + \beta_0), \quad g(z) = \begin{cases} 1, & z \geq 0 \\ -1, & z < 0 \end{cases}$$

Vprašanje: kateri model je najboljši?



Odgovor metode podpornih vektorjev: model z **največjim robom (H3)**.

Rob: grafična ponazoritev in odločitveno pravilo

Odločitveno pravilo


- Za pozitivni primer $\mathbf{x}_{\oplus}$:
 $\beta^T \mathbf{x}_{\oplus} + \beta_0 \geq 1$
- Za negativni primer $\mathbf{x}_{\ominus}$:
 $\beta^T \mathbf{x}_{\ominus} + \beta_0 \leq -1$

Vpeljemo y

- $y = 1$ za primere $\oplus$
- $y = -1$ za primere $\ominus$

$$y (\beta^T \mathbf{x} + \beta_0) \geq 1$$

Enačaj velja natanko na robu.



Rob: grafična ponazoritev in širina roba

Izračun širine roba


$$\frac{\beta^T}{\|\beta\|} (\mathbf{x}_{\oplus} - \mathbf{x}_{\ominus})$$

Prejšnja prosojnica

- $\beta^T \mathbf{x}_{\oplus} + \beta_0 = 1$
- $\beta^T \mathbf{x}_{\ominus} + \beta_0 = -1$

Če odštejemo enačbi

$$\beta^T (\mathbf{x}_{\oplus} - \mathbf{x}_{\ominus}) = 2$$



Osnovna formulacija in konveksna ciljna funkcija

Osnovni optimizacijski problem

$$\max_{\beta, \beta_0} \frac{2}{\|\beta\|}$$

$|S|$ omejitev:

$$y(\beta^T \mathbf{x} + \beta_0) \geq 1, (\mathbf{x}, y) \in S$$

Kako do konveksne ciljne funkcije?

- $\max 1/\|\beta\|$ je ekvivalentno $\min \|\beta\|$
- $\min \|\beta\|$ je ekvivalentno $\min \frac{1}{2}\|\beta\|^2$

Končna formulacija za binarno klasifikacijo

$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2$$

$|S|$ omejitev: $y(\beta^T \mathbf{x} + \beta_0) \geq 1, (\mathbf{x}, y) \in S$

Naloga kvadratnega programiranja

- **Kvadratna in konveksna** ciljna funkcija
- **Linearne** omejitve
- Možno je najti globalni minimum

Dualni problem

Lagrange-ova funkcija s koeficienti $\alpha_{\mathbf{x}}$, $(\mathbf{x}, y) \in S$

$$\mathcal{L}(\boldsymbol{\beta}, \beta_0, \boldsymbol{\alpha}) = \frac{1}{2} \|\boldsymbol{\beta}\|^2 + \sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} \left(1 - \left(\boldsymbol{\beta}^T \mathbf{x} + \beta_0 \right) y \right)$$

Pogoji Karush-Kuhn-Tucker (KKT)

Pogoji KKT za optimalno rešitev $\beta^*, \beta_0^*, \alpha^*$

$$\frac{\partial \mathcal{L}}{\partial \beta} = 0$$

$$\frac{\partial \mathcal{L}}{\partial \beta_0} = 0$$

$$\alpha_{\mathbf{x}}^* \left(1 - \left(\beta^{*T} \mathbf{x} + \beta_0^* \right) y \right) = 0$$

$$1 - \left(\beta^{*T} \mathbf{x} + \beta_0^* \right) y \leq 0$$

$$\alpha_{\mathbf{x}}^* \geq 0$$

Reševanje dualnega problema

Prva dva pogoja KKT upoštevajte $\|\beta\|^2 = \beta^T \beta$ oziroma $\frac{\partial \|\beta\|^2}{\partial \beta} = 2\beta$

$$\frac{\partial \mathcal{L}}{\partial \beta} = \beta - \sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} y \mathbf{x} = 0$$

$$\frac{\partial \mathcal{L}}{\partial \beta_0} = - \sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} y = 0$$

Je izpolnjen, ko

- $\beta = \sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} y \mathbf{x}$
- $\sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} y = 0$

Prvi člen $\mathcal{L}$, če upoštevamo $\beta = \sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} y \mathbf{x}$

$\langle \mathbf{u}, \mathbf{v} \rangle = \mathbf{u}^T \mathbf{v} = \mathbf{v}^T \mathbf{u}$ je oznaka za skalarni produkt vektorjev $\mathbf{u}$ in $\mathbf{v}$.

$$\begin{aligned} \frac{1}{2} \|\beta\|^2 &= \frac{1}{2} \langle \beta, \beta \rangle \\ &= \frac{1}{2} \sum_{(\mathbf{x}_1, y_1) \in S} \sum_{(\mathbf{x}_2, y_2) \in S} \alpha_{\mathbf{x}_1} \alpha_{\mathbf{x}_2} y_1 y_2 \langle \mathbf{x}_1, \mathbf{x}_2 \rangle \end{aligned}$$

Drugi člen $\mathcal{L}$, če upoštevamo $\beta = \sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} y \mathbf{x}$

$$\begin{aligned} \beta^T \mathbf{x} &= \langle \beta, \mathbf{x} \rangle \\ &= \sum_{(\mathbf{x}_2, y_2) \in S} \alpha_{\mathbf{x}_2} y_2 \langle \mathbf{x}, \mathbf{x}_2 \rangle \end{aligned}$$

$$\begin{aligned} \sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} \left(1 - y \left(\beta^T \mathbf{x} + \beta_0 \right) \right) &= \sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} \\ &\quad - \sum_{(\mathbf{x}, y) \in S} \sum_{(\mathbf{x}_2, y_2) \in S} \alpha_{\mathbf{x}} \alpha_{\mathbf{x}_2} y y_2 \langle \mathbf{x}, \mathbf{x}_2 \rangle \\ &\quad - \beta_0 \sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} y \end{aligned}$$

Če upoštevamo zadnji dve prosojnci in $\sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} y = 0$

$$\mathcal{L}(\beta, \beta_0, \alpha) = \sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} - \frac{1}{2} \sum_{(\mathbf{x}_1, y_1) \in S} \sum_{(\mathbf{x}_2, y_2) \in S} \alpha_{\mathbf{x}_1} \alpha_{\mathbf{x}_2} y_1 y_2 \langle \mathbf{x}_1, \mathbf{x}_2 \rangle$$

Torej, končna formulacija dualnega problema

$$\max_{\alpha} \sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} - \frac{1}{2} \sum_{(\mathbf{x}_1, y_1) \in S} \sum_{(\mathbf{x}_2, y_2) \in S} \alpha_{\mathbf{x}_1} \alpha_{\mathbf{x}_2} y_1 y_2 \langle \mathbf{x}_1, \mathbf{x}_2 \rangle$$

$|S| + 1$ linearnih omejitev (iz drugega in petega pogoja KKT)

- $\alpha_{\mathbf{x}} \geq 0, (\mathbf{x}, y) \in S$
- $\sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} y = 0$

V dualni formulaciji in pri napovedovanju nastopajo le skalarni produkti.

Napoved in podporni vektorji

Napoved $\hat{y}_0$ za primer $\mathbf{x}_0$

$$\begin{aligned}\hat{y}_0 &= g \left(\left\langle \sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} y \mathbf{x}, \mathbf{x}_0 \right\rangle + \beta_0 \right) \\ &= g \left(\sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} y \langle \mathbf{x}, \mathbf{x}_0 \rangle + \beta_0 \right)\end{aligned}$$


Vsoto v zgornji formuli računamo zgolj za tiste primere $\mathbf{x}$, kjer $\alpha_{\mathbf{x}} > 0$.

Te primere imenujemo podporni vektorji $\mathbf{x}_s$



- Iz $\alpha_{\mathbf{x}_s} > 0$ in komplementarnega pogoja KKT sledi
 $y (\boldsymbol{\beta}^T \mathbf{x}_s + \beta_0) = 1$
- Torej, podporni vektorji $\mathbf{x}_s$ ležijo na robu

Podporni vektorji in rob

Na sliki je w oznaka za β in b oznaka za β_0 .



Visoka varianca in občutljivost na šumne podatke



In kaj lahko naredimo, če razreda nista linearno ločljiva?


Kaj pa, če podatki niso linearno ločljivi?

Alternativna formulacija za podatke, ki niso linearno ločljivi

$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2 + C \sum_{(\mathbf{x}, y) \in S} \xi_{\mathbf{x}}$$

$2|S|$ linearnih omejitev:

- $y (\beta^T \mathbf{x} + \beta_0) \geq 1 - \xi_{\mathbf{x}}, (\mathbf{x}, y) \in S$
- $\xi_{\mathbf{x}} \geq 0, (\mathbf{x}, y) \in S$



Dualni problem in podporni vektorji

$$\max_{\alpha} \sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} - \frac{1}{2} \sum_{(\mathbf{x}_1, y_1) \in S} \sum_{(\mathbf{x}_2, y_2) \in S} \alpha_{\mathbf{x}_1} \alpha_{\mathbf{x}_2} y_1 y_2 \langle \mathbf{x}_1, \mathbf{x}_2 \rangle$$

$2|S| + 1$ linearnih omejitev

- $0 \leq \alpha_{\mathbf{x}} \leq C, (\mathbf{x}, y) \in S$
- $\sum_{(\mathbf{x}, y) \in S} \alpha_{\mathbf{x}} y = 0$

Podporni vektorji so v tem primeru lahko tudi znotraj roba

- Na robu $0 < \alpha_{\mathbf{x}_s} < C: y (\beta^T \mathbf{x}_s + \beta_0) = 1$
- Znotraj roba $\alpha_{\mathbf{x}_s} = C: y (\beta^T \mathbf{x}_s + \beta_0) < 1$

Vloga parametra C (cena): pristranskost in varianca

$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2 + C \sum_{(\mathbf{x}, y) \in S} \xi_{\mathbf{x}}$$

Večanje vrednosti C


- Optimizacija se osredotoča na drugi člen formule, zmanjševanje $\xi_{\mathbf{x}}$
- Torej na čim boljšem ločevanju razredov
- Potegne model v smer **višje variance in manjše pristranskosti**
- Podobno kot malo število sosedov k pri metodi najbližjih sosedov

Manjšanje vrednosti C




- $\xi_{\mathbf{x}}$ so lahko veliki, zato ločevanje razredov ni tako pomembno
- **Zniža se varianca in poveča pristranskost**
- Pozor: **poveča se tudi število podpornih vektorjev znotraj roba**

Klasifikacija s podpornimi vektorji: cena C

Oznake na grafih: število podpornih vektorjev.



Klasifikacija s podpornimi vektorji: vpliv vrednosti C



Alternativni metodi za več kot dva razreda, $|D_Y| > 2$

Metoda ena-na-ena, $|D_Y|(|D_Y| - 1)/2$ modelov

- En model za vsako podmnožico $\{v_1, v_2\} \subset D_Y$
 - Izberemo primere $S' = \{(\mathbf{x}, y) \in S : y \in \{v_1, v_2\}\}$
 - Zgradimo model iz S' , kjer v_1 spremenimo v 1, v_2 v -1
- Iz napovedi teh modelov izberemo večinsko napoved

Metoda en-proti-vsem, $|D_Y|$ modelov


- En model za vsako vrednost $v \in D_Y$
- Zgradimo model iz S' , kjer vrednosti spremenljivke Y , ki so enake v , spremenimo v 1, druge vrednosti pa v -1
- Napovemo razred, katerega napoved je najbolj oddaljena od roba

Regresija, $D_Y \subset \mathbb{R}$

$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2 + C \sum_{(\mathbf{x}, y) \in S} V_\epsilon \left(y - (\beta^T \mathbf{x} + \beta_0) \right)$$

Funkcija V_ϵ , $\epsilon \in \mathbb{R}_{>0}$

$$V_\epsilon(r) = \begin{cases} 0, & |r| \leq \epsilon \\ |r| - \epsilon, & |r| > \epsilon \end{cases}$$



Vloga parametrov cena (C) in ϵ

$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2 + C \sum_{(\mathbf{x}, y) \in S} V_{\epsilon}(y - (\beta^T \mathbf{x} + \beta_0))$$

Parameter cena uravnava kompromis med pristranskostjo in varianco


- Z **manjšanjem** C se optimizacija osredotoča na male vrednosti β (regularizacija), kar **zmanjša varianco in poveča pristranskost**
- Večja pristranskost, manj kompleksni modeli in **praviloma** manj podpornih vektorjev (obvezno opazovanje njihovega števila)

Parameter ϵ

- Vpliv nepredvidljiv, zato običajno privzeta vrednost $\epsilon = 0.1$
- Vrednosti spremenljivk X in Y običajno standardiziramo

Regresija s podpornimi vektorji: cena C

Oznake na grafih: število podpornih vektorjev.




Jedrne funkcije

Transformacija ϕ prostora napovednih spremenljivk X

$$X' = \phi(X)$$

Primer kvadratne transformacije $\phi(\{X_1, X_2\}) = \{X_1^2, X_2^2\}$



Nelinearna odločitvena meja postane linearna.

Definicija in pomen

Definicija jedrne funkcije $K : \times_{i=1}^p D_i \times \times_{i=1}^p D_i \rightarrow \mathbb{R}$

$$K(\mathbf{u}, \mathbf{v}) = \langle \phi(\mathbf{u}), \phi(\mathbf{v}) \rangle$$

Vrne vrednost skalarnega produkta transformiranih vektorjev.

Primer s prejšnje prosojnice

$$K(\mathbf{u}, \mathbf{v}) = \langle (u_1^2, u_2^2), (v_1^2, v_2^2) \rangle = u_1^2 v_1^2 + u_2^2 v_2^2$$

Jedrni trik

Z jedrno funkcijo skalarni produkt vektorjev v transformiranem prostoru izračunamo brez potrebe po prehodu v transformirani prostor.

Primer jedrne funkcije $K(\mathbf{u}, \mathbf{v}) = (\langle \mathbf{u}, \mathbf{v} \rangle + 1)^2$

$$\begin{aligned}(\langle \mathbf{u}, \mathbf{v} \rangle + 1)^2 &= (u_1 v_1 + u_2 v_2 + 1)^2 \\&= u_1^2 v_1^2 + u_2^2 v_2^2 + 1 + 2u_1 u_2 v_1 v_2 + 2u_1 v_1 + 2u_2 v_2 \\&= \langle \phi(\mathbf{u}), \phi(\mathbf{v}) \rangle\end{aligned}$$

$$\phi(\mathbf{u}) = (u_1^2, u_2^2, 1, \sqrt{2}u_1 u_2, \sqrt{2}u_1, \sqrt{2}u_2)$$

S pomočjo jedrnega trika lahko izračunamo model podpornih vektorjev v šestdimenzionalnem prostoru, čeprav je X dvodimenzionalen.

Pogosto uporabljene jedrne funkcije (jedra)

Polinomsko jedro, stopnja d

$$K(\mathbf{u}, \mathbf{v}) = (1 + \langle \mathbf{u}, \mathbf{v} \rangle)^d$$

Dimenzija transformiranega prostora $O(p^d)$.

Gaussovo (radialno) jedro $\gamma = 1/(2\sigma^2)$

$$K(\mathbf{u}, \mathbf{v}) = e^{-\gamma \|\mathbf{u} - \mathbf{v}\|^2}$$

Sorodni jedri sta eksponentno in Laplacovo. Dimenzija ∞ .

Sigmoidno (nevronske) jedro, κ_1, κ_2

$$K(\mathbf{u}, \mathbf{v}) = \tanh(\kappa_1 \langle \mathbf{u}, \mathbf{v} \rangle + \kappa_2)$$

Dimenzija transformiranega prostora ∞ .

Jedrna matrika in Mercerjev izrek

Jedrna matrika K za podatkovno množico S

- Dimenzije matrike $|S| \times |S|$
- Elementi $K_{ij} = K(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle, (\mathbf{x}_i, y_i), (\mathbf{x}_j, y_j) \in S$
- Zaradi komutativnosti skalarne produkta je K simetrična


Mercerjev izrek

Nujni in zadostni pogoj zato, da matrika K določa veljavno jedro, je to, da je K simetrična in pozitivno semidefinitna, t.j., $\forall \mathbf{z} \in \mathbb{R}^{|S|} : \mathbf{z}^T K \mathbf{z} \geq 0$.


Posledici

- K lahko obravnavamo kot matriko podobnosti med primeri
- Prostor možnih jeder zelo velik


Klasifikacija s polinomskim jedrom: Cena in stopnja jedra




Klasifikacija s polinomskim jedrom stopnje $d = 2$




Klasifikacija z Gaussovim jedrom: Cena in širina jedra




Klasifikacija z Gaussovim jedrom širine $\gamma = 0.1$




Regresija s polinomskim jedrom: Cena in stopnja jedra




Regresija s polinomskim jedrom stopnje $d = 2$



Regresija z Gausovim jedrom: Cena in širina jedra



Regresija z Gausovim jedrom s širino $\gamma = 0.01$ 

Primerjava napak

Klasifikacija, klasifikacijska napaka CE

- Linearno jedro, $C = 0.1$: 0.47
- Polinomsko jedro stopnje $d = 2$, cena $C = 0.1$: **0.29**
- Gaussovo jedro širine $\gamma = 0.1$, $C = 10$: **0.29**

Regresija, celotna napaka $RMSE$

- Linearno jedro, $C = 0.01$: 0.2817
- Polinomsko jedro stopnje $d = 2$, cena $C = 0.1$: 0.1420
- Gaussovo jedro širine $\gamma = 0.01$, $C = 1,000$: **0.1215**

Znani algoritmi in implementacije

Originalni predlog (Vapnik in Chervonenkis 1963)

Optimizacija roba za linearno ločljiva razreda.

Nadgradnja in posplošitev (Cortes in Vapnik 1995)

Knjižnica LIBSVM (C++ in Java), na voljo tudi kot paket e1071 v R-ju.

Python in scikit-learn

- Razred SVC za klasifikacijo, SVR za regresijo
- Alternative LinearSVC, LinearSVR, nuSVC in nuSVR