

Nenadzorovano razvrščanje v skupine

Ljupčo Todorovski

Univerza v Ljubljani, Fakulteta za matematiko in fiziko
Institut Jožef Stefan, Odsek za tehnologije znanja (E8)

April 2026

Pregled predavanja

- 1 Definicija naloge
- 2 Hierarhično razvrščanje v skupine
 - Algoritem HAC
 - Razdalja med skupinami, *linkage*
 - Primer
- 3 Algoritem k-tih voditeljev, *k-means*
 - Optimizacijski problem in algoritem
 - Primer
- 4 Vrednotenje kvalitete
 - Obrisi, *silhouettes*
 - Druge mere

Nadzorovano in nenadzorovano učenje

Nadzorovano učenje

- Podatkovna množica $S \subseteq D_{X_1} \times D_{X_2} \times \dots \times D_{X_p} \times D_Y$
- Primeri $e = (\mathbf{x}, y) = (x_1, x_2, \dots, x_p, y), x_i \in D_{X_i}, y \in D_Y$
- Rezultat je napovedni model, funkcija $m : D_{X_1} \times \dots \times D_{X_p} \rightarrow D_Y$

Nenadzorovano učenje, brez ciljne spremenljivke Y

- Podatkovna množica $S \subseteq D_{X_1} \times D_{X_2} \times \dots \times D_{X_p}$
- Primeri $e = (x_1, x_2, \dots, x_p), x_i \in D_{X_i}$
- Rezultat so vzorci

Dva običajna tipa vzorcev

Skupine primerov, klastri

- To so množice primerov, ki so si **medsebojno podobni**
- Algoritmi za razvrščanje v skupine, *clustering*

Pogoste množice postavk, *frequent itemsets*

- To so vrednosti spremenljivk, ki se pogosto pojavljajo skupaj
- Algoritem APRIORI za odkrivanje pogostih množic postavk
- Algoritem za odkrivanje povezovalnih pravil, *association rules*

Naloga razvrščanja v skupine: Vhodi

Vhodi

- Učna množica S primerov za nenadzorovano učenje
- Želeno oziroma pričakovano število skupin k
- Mera razdalje med primeri $d: S \times S \rightarrow \mathbb{R}$

Mera razdalje med primeri

Funkcija $d: S \times S \rightarrow \mathbb{R}$ z lastnostmi

- $\forall u \in S: d(u, u) = 0$
- $\forall u, v \in S, u \neq v: d(u, v) > 0$
- $\forall u, v \in S: d(u, v) = d(v, u)$
- $\forall u, v, w \in S: d(u, w) \leq d(u, v) + d(v, w)$

Ob predpostavki $S \subset \mathbb{R}^p$, uporabljamo razdalje Minkovskega

$$d(u, v) = \left(\sum_{i=1}^p |u_i - v_i|^q \right)^{\frac{1}{q}}$$

$q = 2$ Evklidska razdalja

$q = 1$ Manhattanska razdalja

Naloga razvrščanja v skupine: Rezultat

Razbitje $\mathcal{C}$ množice S na k podmnožic, imenovanih skupine (*clusters*)

- $\forall C \in \mathcal{C}: C \neq \emptyset$, vsaka skupina ima vsaj en primer
- $\forall C_1, C_2 \in \mathcal{C}, C_1 \neq C_2: C_1 \cap C_2 = \emptyset$, vsak primer pripada **le** eni skupini
- $\bigcup_{C \in \mathcal{C}} C = S$, vsak primer pripada **vsaj** eni skupini

Skupine so **kompaktne**: za primere iz skupine $C \in \mathcal{C}$ velja

- So **blizu** drugim primerom iz C
- So **čim dlje** od primerov v drugih skupinah iz $\mathcal{C} \setminus \{C\}$

Iterativni algoritem za hierarhično razvrščanje

Require: S je množica primerov e

Require: D je **mera razdalje med skupinami**

Ensure: $\mathcal{D}$ je dendrogram, hierarhija skupin

```
function HAC( $S, D$ )
```

```
   $\mathcal{C} = \{\{e\} : e \in S\}$ 
```

```
  for  $i = 1$  to  $|S| - 1$  do
```

```
     $C_1$  in  $C_2$  sta najbližji skupini iz  $\mathcal{C}$ 
```

```
     $\forall \mathcal{D}$  na višini  $D(C_1, C_2)$  združi  $C_1$  in  $C_2$  v eno skupino  $C_1 \cup C_2$ 
```

```
     $\mathcal{C} = \mathcal{C} \setminus \{C_1, C_2\} \cup \{C_1 \cup C_2\}$ 
```


```
  end for
```

```
  return  $\mathcal{D}$ 
```

```
end function
```

HAC = *Hierarchical Agglomerative Clustering*

Rezultat: Hierarhija skupin, imenovana dendrogram



hclust (*, "complete")

Višina združevanja na osi y


Razdalja med skupinami $\{x, w\}$ in $\{u, z\}$ je približno 1.

Od dendrograma $\mathcal{D}$ do razbitja $\mathcal{C}$


Rezanje dendrograma

- Povlečemo horizontalno črto, ki »reže« veje dendrograma k krat
- In torej »izreže« dendrogram na k (pod)dreves
- Vsako izrezano drevo vsebuje primere ene skupine

Višina združevanja v dendrogramu



Višina združevanja v dendrogramu in optimalna vrednost k



Definicija

Funkcija $D: 2^S \times 2^S \rightarrow \mathbb{R}$

Izračuna razdaljo med dvema podanima množicama primerov.

Dve možnosti za definicijo D

- Z združevanjem vrednosti razdalj med primeri
- Rekurzivno: od manjših množic proti večjim

Z združevanjem vrednosti razdalj med primeri

$$D(C_1, C_2) = \underset{(u,v) \in C_1 \times C_2}{\text{agg}} \quad d(u, v)$$

Običajne variante z različnimi funkcijami združevanja *agg*

max celovita razdalja med primeri, *complete linkage*

min enojna razdalja med primeri, *single linkage*

mean povprečna razdalja med primeri, *average linkage*

Wardova rekurzivna formula

$$D(C_1 \cup C_2, C) = \alpha_1 D(C_1, C) + \alpha_2 D(C_2, C) + \beta D(C_1, C_2)$$
$$D(\{u\}, \{v\}) = d(u, v)$$

Wardova razdalja med skupinami, vrednosti koeficientov


$$\alpha_i = \frac{|C_i| + |C|}{|C_1| + |C_2| + |C|} > 0$$
$$\beta = -\frac{|C|}{|C_1| + |C_2| + |C|} < 0$$

Pomen treh členov v Wardovi rekurzivni formuli


- 1 Je prispevek primerov iz C_1 k razdalji med $C_1 \cup C_2$ in C
- 2 Je prispevek primerov iz C_2 k razdalji med $C_1 \cup C_2$ in C
- 3 Zmanjševanje zaradi **podvojenega** upoštevanja razdalje med C_1 in C_2

Analogija z načelom vključitev in izključitev.

Podatki za razvrščanje: Dva kroga




Primer dendrograma: Complete linkage, MAX




```
hclust (*, "complete")
```

Od dendrograma do skupin: Dve skupini



Od dendrograma do skupin: Štiri skupine



Centroid in varianca skupine primerov

Centroid c skupine primerov S

$$c = \arg \min_{u \in \mathbb{R}^p} \sum_{v \in S} d(u, v)^2$$

- Točka $c \in \mathbb{R}^p$, ki je **najmanj oddaljena od primerov iz množice S**
- Predpostavka $S \subset \mathbb{R}^p$ in, pozor, c **ni nujno** primer iz S
- Tako definiran centroid za Evklidsko razdaljo je aritmetična sredina

Vsota kvadratov razdalj primerov iz S od centroida imenujemo varianca

$$\text{Var}(S) = \frac{1}{|S|} \sum_{v \in S} d(c, v)^2$$

Minimalna varianca in Evklidska razdalja: Izpeljava

Odvajamo varianco po i -ti komponenti u_i točke u

$$\begin{aligned}\frac{\partial}{\partial u_i} \sum_{v \in S} d(u, v)^2 &= \sum_{v \in S} \sum_{j=1}^p \frac{\partial}{\partial u_i} (u_j - v_j)^2 \\ &= \sum_{v \in S} 2(u_i - v_i) \\ &= 2 \sum_{v \in S} (u_i - v_i)\end{aligned}$$

Centroid za Evklidsko razdaljo

Za ekstrem izenačimo z nič

$$\begin{aligned}\sum_{v \in S} (c_i - v_i) &= 0 \\ \sum_{v \in S} c_i - \sum_{v \in S} v_i &= 0 \\ |S|c_i &= \sum_{v \in S} v_i\end{aligned}$$

Torej je centroid za Evklidsko razdaljo pravzaprav »povprečen«
primer

$$c_i = \frac{1}{|S|} \sum_{v \in S} v_i \quad \text{oziroma v vektorski obliki} \quad c = \frac{1}{|S|} \sum_{v \in S} v$$

Razvrščanje v skupine kot optimizacijski problem

$$\min_{\mathcal{C}: |\mathcal{C}|=k} \sum_{C \in \mathcal{C}} |C| \operatorname{Var}(C)$$

Najdi razbitje $\mathcal{C}$ učne množice S na k skupin

- Minimiziramo varianco primerov znotraj skupin
- Ker je celotna varianca v podatkih iz $|S|$ nespremenljiva, maksimiramo ločevanje skupin, to je, razdaljo med primeri v različnih skupinah

Iterativni algoritem za optimizacijo (Lloyd)

Require: S je množica primerov e

Require: k je želeno število skupin

Require: d je mera razdalje med primeri

```
1: function KMeans( $S, k, d$ )
2:    $\mathcal{C}$  = naključno razbitje primerov iz  $S$  v  $k$  skupin
3:   repeat
4:     for  $C \in \mathcal{C}$  do
5:        $c_C = \text{Centroid}(C, d)$ 
6:     end for
7:     for  $u \in S$  do
8:        $C = \arg \min_{C \in \mathcal{C}} d(u, c_C)$ , prestavi  $u$  v  $C$ 
9:     end for
10:  until razbitje  $\mathcal{C}$  se ni spremenilo v zadnji iteraciji
11:  return  $\mathcal{C}$ 
12: end function
```

Dva ključna koraka algoritma

Korak posodobitve centroidov, *Update*

- Vrstice 4 do 6 v algoritmu na prejšnji prosojnici
- Vsaki skupini $C \in \mathcal{C}$ izračunamo centroid
- Izračun centroida določa mera d razdalje med primeri
- Algoritem k-tih voditeljev **predpostavi Evklidsko razdaljo**

Korak uvrščanja primerov, *Assignment*

- Vrstice 7 do 9 v algoritmu na prejšnji prosojnici
- Vsak primer $u \in S$ dodelimo skupini s centroidom, ki je najbližji u
- Če kakšna skupina ostane prazna, ji dodelimo primer, ki je najbolj oddaljen od »svojega« centroida

Različica k-medoids: Medoidi namesto centroidov

Za poljubno podano mero razdalje d


- Se lahko zgodi, da optimizacijski problem ni analitično rešljiv
- Lahko je izračun centroida nedopustno drag ali nemogoč

Zato centroid c nadomestimo z medoidom m

$$m = \arg \min_{u \in S} \sum_{v \in S} d(u, v) \quad \text{namesto} \quad c = \arg \min_{u \in \mathbb{R}^p} \sum_{v \in S} d(u, v)^2$$

Medoid je **element** množice, centroid pa ne nujno.

Dve skupini (k-means): podatki



Problem

Kako ovrednotimo kvaliteto razvrščanja v skupine?

Koristi od vrednotenja, izbira

- Algoritma za razvrščanje v skupine
- Nastavitev algoritma za razvrščanje v skupine
- Števila skupin k

Osnovna ideja

Kvaliteta razvrščanja posameznega primera odvisna od

- **Povezanosti** s primeri iz iste skupine
- **Ločenosti** od primerov iz drugih skupin

Povezanost a s primeri iz iste skupine

$$a(u, \mathcal{C}) = \begin{cases} \frac{1}{|C_u|-1} \sum_{v \in C_u \setminus \{u\}} d(u, v), & \text{če } |C_u| > 1 \\ 0, & |C_u| = 1 \end{cases}$$

- $C_u \in \mathcal{C}$ je skupina, kateri pripada primer u
- $a(u, \mathcal{C})$ je **povprečna razdalja** u do ostalih primerov v njegovi skupini
- $a(u, \mathcal{C}) \geq 0$, **manjše** vrednosti boljše

Ločenost b od primerov iz drugih skupin

$$b(u, \mathcal{C}) = \min_{C \in \mathcal{C} \setminus \{C_u\}} \frac{1}{|C|} \sum_{v \in C} d(u, v)$$

- C_u je skupina, kateri pripada primer u
- $b(u, \mathcal{C})$ je min. povprečnih razdalj u do primerov v drugih skupinah
- $b(u, \mathcal{C}) \geq 0$, večje vrednosti boljše

Razlika med ločenostjo in povezanostjo

$$s(u, \mathcal{C}) = \frac{b(u, \mathcal{C}) - a(u, \mathcal{C})}{\max\{a(u, \mathcal{C}), b(u, \mathcal{C})\}}$$

Vrednost obrisa $-1 \leq s(u, \mathcal{C}) \leq 1$


- V primeru $a(u, \mathcal{C}) = b(u, \mathcal{C}) = 0$ je vrednost $s(u, \mathcal{C}) = 0$
- Vrednost blizu 1: $b(u, \mathcal{C}) \gg a(u, \mathcal{C})$: u je dobro ločen od drugih skupin in zelo povezan s svojo skupino, torej **dobro razvrščen**
- Vrednost blizu -1 : $b(u, \mathcal{C}) \ll a(u, \mathcal{C})$: u je slabo ločen od drugih skupin in slabo povezan s svojo skupino, torej **slabo razvrščen**

Povprečje obrisov primerov iz S

Mera kvalitete razvrščanja v skupine $\mathcal{C}$

$$\bar{s}(\mathcal{C}) = \frac{1}{|S|} \sum_{u \in S} s(u, \mathcal{C})$$

Primerjava povprečij obrisov na podatkih



Dunnov indeks

$$DI(\mathcal{C}) = \frac{\min_{C_1, C_2 \in \mathcal{C}: C_1 \neq C_2} D(C_1, C_2)}{\max_{C \in \mathcal{C}} \Delta_C}$$

$DI(\mathcal{C}) \geq 0$, večje vrednosti boljše

- Števec: minimalna razdalja D med skupinami, ločenost skupin
- Imenovalec: največja razpršenost primerov v posamezni skupini

Razpršenost Δ_C primerov v skupini C

Tri različice, c_C je centroid skupine C , d je razdalja med primeri

$$\Delta_C = \max_{u,v \in C} d(u, v)$$

$$\Delta_C = \frac{2}{|C|(|C| - 1)} \sum_{u,v \in C: u \neq v} d(u, v)$$

$$\Delta_C = \frac{1}{|C|} \sum_{u \in C} d(u, c_C)$$

Calinski–Harabaszov indeks

$$CH(\mathcal{C}) = \frac{BCSS(\mathcal{C})/(k-1)}{WCSS(\mathcal{C})/(|S|-k)}$$

$CH(\mathcal{C}) \geq 0$, večje vrednosti boljše

$BCSS$ je ločenost skupin

$WCSS$ je vsota nepovezanosti primerov v posameznih skupinah

BCSS in WCSS

Ločenost med skupinami, *BCSS*

$$BCSS = \sum_{C \in \mathcal{C}} |C| d(c_C, c_S)^2$$

c_C in c_S so centroidi skupin in celotne množice primerov S .

Vsota nepovezanosti primerov v posameznih skupinah, *WCSS*

$$WCSS = \sum_{C \in \mathcal{C}} \sum_{u \in C} d(u, c_C)^2$$

Primerjava med merami kvalitete

Mera kakovosti	Potrebe
Obrisi	Zgolj mera razdalje med primeri d
Dunnov indeks	d , mera razdalje med skupinami D v eni različici tudi centroidi skupin
Calinski–Harabaszov indeks	d , centroidi skupin

Znani algoritmi in implementacije

Hierarhično razvrščanje v skupine (Florek in ost 1951)

- Modul `sklearn.cluster`, razred `AgglomerativeClustering`
- V R-ju vgrajeni funkciji `hclust` in `cutree`.

Algoritem k-tih voditeljev (Lloyd 1957)

- Modul `sklearn.cluster`, razred `KMeans`
- V R-ju vgrajena funkcija `kmeans`

Vrednotenje kvalitete razvrščanja

Modul `sklearn.metrics`, `silhouette_score` in `calinski_harabasz_score`.